PROPOSAL TUGAS AKHIR – ES234849

TERRA-LANDSLIDE: Pengembangan Website Klasifikasi Kerawanan Tanah Longsor di Indonesia Berbasis *Stacking Ensemble Learning* dan Variable Neighborhood Search

NADIA AYULA ASSYAPUTRI

NRP 5026231090

Dosen Pembimbing

Amalia Utamima, S.Kom., M.BA., Ph.D.

NIP 19861213 201504 2 001

Program Studi Sistem Informasi

Departemen Sistem Informasi

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

LEMBAR PENGESAHAN

TERRA-LANDSLIDE: Pengembangan Website Klasifikasi Kerawanan Tanah Longsor di Indonesia Berbasis *Stacking Ensemble Learning* dan Variable Neighborhood Search

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat

memperoleh gelar S.Kom. pada

Program Studi S-1 Sistem Informasi

Departemen Sistem Informasi

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Oleh : **NADIA AYULA ASSYAPUTRI**

NRP. 5026231090

Disetujui oleh Tim Penguji Proposal Tugas Akhir :

1. Amalia Utamima, S.Kom., M.BA., Ph.D. Pembimbing
2. Retno Aulia Vinarti, S.Kom, M.Kom., Ph.D. Penguji
3. Edwin Riksakomara, S.Kom., M.T. Penguji

SURABAYA

Juni, 2026

ABSTRAK

TERRA-LANDSLIDE: Pengembangan Website Klasifikasi Kerawanan Tanah Longsor di Indonesia Berbasis Stacking Ensemble Learning dan Variable Neighborhood Search

Nama Mahasiswa / NRP	**:**	**Nadia Ayula Assyaputri / 5026231090**
Departemen	**:**	**Sistem Informasi FTEIC - ITS**
Dosen Pembimbing	**:**	**Amalia Utamima, S.Kom., M.BA., Ph.D.**

Abstrak

Indonesia merupakan negara dengan tingkat kerawanan bencana alam yang tinggi, salah satunya tanah longsor. Berdasarkan rekapitulasi pada portal GIS BNPB, kejadian tanah longsor di Indonesia tercatat sebanyak 212 kejadian pada tahun 2024 dan meningkat menjadi 246 kejadian pada tahun 2025. Kondisi tersebut menunjukkan perlunya pendekatan berbasis data untuk membantu penyajian informasi kerawanan tanah longsor secara lebih mudah dipahami. Tugas akhir ini bertujuan untuk mengembangkan TERRA-LANDSLIDE, yaitu sistem klasifikasi kerawanan tanah longsor berbasis web yang menjadi bagian dari sistem TERRA. Sistem ini mengklasifikasikan wilayah ke dalam tiga kelas kerawanan, yaitu rendah, sedang, dan tinggi. Data yang digunakan mencakup data historis kejadian tanah longsor periode 2019–2025 dari GIS BNPB serta data spasial faktor pemicu dari Google Earth Engine (GEE), NASA, dan sumber spasial pendukung lainnya. Faktor yang digunakan meliputi curah hujan, elevasi, kemiringan lereng, tutupan lahan, jenis tanah, kelembapan tanah, indeks vegetasi, dan variabel pendukung lain sesuai ketersediaan data. Metode utama yang digunakan adalah *stacking ensemble learning* dengan pengujian awal beberapa algoritma machine learning untuk menentukan kandidat *base learner* dan *meta-learner*. Selanjutnya, Variable Neighborhood Search (VNS) digunakan untuk mengoptimalkan feature selection dan hyperparameter tuning. Model dievaluasi menggunakan *accuracy, precision, recall, F1-score,* dan *confusion matrix,* serta diinterpretasikan menggunakan SHAP. Model final diintegrasikan ke sistem web TERRA untuk menampilkan peta kerawanan, ringkasan wilayah, faktor dominan, dan rekomendasi mitigasi berbasis aturan.

Kata kunci: kerawanan tanah longsor, *machine learning*, *stacking ensemble learning*, Variable Neighborhood Search, TERRA-LANDSLIDE.

ABSTRACT

TERRA-LANDSLIDE: A Web-Based Landslide Susceptibility Classification System Using VNS-Optimized Stacking Ensemble Learning

Student Name / NRP	**:**	**Nadia Ayula Assyaputri / 5026231090**
Department	**:**	**Sistem Informasi FTEIC - ITS**
Advisor	**:**	**Amalia Utamima, S.Kom., M.BA., Ph.D.**

Abstract

Indonesia is highly susceptible to natural disasters, including landslides. Based on the GIS BNPB portal recap, landslide events in Indonesia were recorded at 212 occurrences in 2024 and increased to 246 occurrences in 2025. This condition highlights the need for a data-driven approach to support the delivery of landslide susceptibility information in a more understandable form. This final project aims to develop TERRA-LANDSLIDE, a web-based landslide susceptibility classification system integrated into TERRA. The system classifies areas into three susceptibility levels: low, medium, and high. The data used include historical landslide event data from 2019 to 2025 obtained from GIS BNPB, as well as spatial data representing landslide conditioning factors obtained from Google Earth Engine (GEE), NASA, and other supporting spatial data sources. The factors include rainfall, elevation, slope, land cover, soil type, soil moisture, vegetation index, and other relevant variables based on data availability. The main method applied is stacking ensemble learning, preceded by the evaluation of several machine learning algorithms to determine candidate base learners and meta-learners. Furthermore, Variable Neighborhood Search (VNS) is used to optimize feature selection and hyperparameter tuning. Model performance is evaluated using accuracy, precision, recall, F1-score, and confusion matrix, while SHAP is applied to interpret feature contributions. The final model is integrated into the TERRA web system to present susceptibility maps, regional summaries, dominant factors, and rule-based mitigation recommendations.

Keywords: ***landslide susceptibility, machine learning, stacking ensemble learning, Variable Neighborhood Search, TERRA-LANDSLIDE.***

DAFTAR ISI

LEMBAR PENGESAHAN **i**

ABSTRAK **ii**

ABSTRACT **iii**

DAFTAR ISI **iv**

DAFTAR GAMBAR **vi**

DAFTAR TABEL **vii**

BAB 1 PENDAHULUAN **8**

1.1 Latar Belakang 8

1.2 Rumusan Masalah 10

1.3 Batasan Masalah 10

1.4 Tujuan 10

1.5 Manfaat 11

1.6 Relevansi Tugas Akhir 11

BAB 2 TINJAUAN PUSTAKA **12**

2.1 Hasil Penelitian Terdahulu 12

2.1.1 Sintesis Penelitian Terdahulu 16

2.2 Dasar Teori 17

2.2.1 Tanah Longsor 17

2.2.2 Kerawanan Bencana 17

2.2.3 Klasifikasi Kerawanan Tanah Longsor 17

2.2.4 Machine Learning 18

2.2.5 Feature Selection 18

2.2.6 Hyperparameter Tuning 18

2.2.7 Cross-Validation 5-Fold 19

2.2.8 Stacking Ensemble Learning 19

2.2.9 Variable Neighborhood Search (VNS) 20

2.2.10 SHAP dan Interpretasi Model 21

2.2.11 Metrik Evaluasi 22

2.2.12 *Web Dashboard* Visualisasi 23

2.2.13 Rekomendasi Mitigasi Berbasis Aturan 23

BAB 3 METODOLOGI **24**

3.1 Metode yang Digunakan 24

3.2 Alur Pelaksanaan Tugas Akhir 24

3.2.1 Identifikasi Masalah 26
3.2.2 Studi Literatur 26
3.2.3 Pengumpulan Data 26
3.2.4 Pembentukan Dataset 27
3.2.5 Pra-Pemrosesan Data 27
3.2.6 Seleksi Fitur Awal 27
3.2.7 Uji Beberapa Model Individual 28
3.2.8 *Stacking Ensemble* Default 28
3.2.9 Optimasi dengan *Metaheuristic* 28
3.2.10 Evaluasi dan Interpretasi 28
3.2.11 Analisis Kebutuhan Sistem 29
3.2.12 Perancangan Sistem Web 29
3.2.13 Pengembangan *Prototype* Web 29
3.2.14 Integrasi Model Prediksi 29
3.2.15 Visualisasi Hasil Prediksi 30
3.2.16 Pengujian Integrasi Sistem 30
3.2.17 Evaluasi Website (*Black-box Testing)* 30
3.2.18 Evaluasi Pengguna dan *Expert Review* 30
3.2.19 Analisis Hasil dan Pelaporan 31
3.3 Sketsa Dashboard Website TERRA 31
3.4 Rencana Pelaksanaan Tugas Akhir 33
DAFTAR PUSTAKA **34**

DAFTAR GAMBAR

Gambar 1.1 Roadmap Laboratorium Rekayasa Data dan Intelegensi Bisnis 11
Gambar 2.1 Ilustrasi *Stratified 5-Fold Cross-Validation* 19
Gambar 2.2 Arsitektur *stacking ensemble learning*. Sumber: Jiang et al. (2019) 20
Gambar 2.3 Ilustrasi Algoritma Variable Neighborhood Search (VNS): Proses Pencarian dan Pseudocode. Sumber: Pambudi dan Kawamura (2022) 21
Gambar 2.4 Contoh *Confusion Matrix* Klasifikasi Tiga Kelas Kerawanan 22
Gambar 3.1 Flowchart Alur Metodologi Tugas Akhir 25
Gambar 3.2 Tampilan Filter Data Kejadian Tanah Longsor pada Portal GIS BNPB 26
Gambar 3.3 Sketsa Dashboard TERRA-LANDSLIDE 32
Gambar 3.4 Sketsa Dashboard TERRA-FLOOD 32
Gambar 3.5 Rencana Pelaksanaan Tugas Akhir 33

DAFTAR TABEL

Tabel 2.1 Keterkaitan Penelitian 1 12
Tabel 2.2 Keterkaitan Penelitian 2 12
Tabel 2.3 Keterkaitan Penelitian 3 13
Tabel 2.4 Keterkaitan Penelitian 4 13
Tabel 2.5 Keterkaitan Penelitian 5 13
Tabel 2.6 Keterkaitan Penelitian 6 14
Tabel 2.7 Keterkaitan Penelitian 7 14
Tabel 2.8 Keterkaitan Penelitian 8 14
Tabel 2.9 Keterkaitan Penelitian 9 15
Tabel 2.10 Keterkaitan Penelitian 10 15
Tabel 2.11 Keterkaitan Penelitian 11 15
Tabel 2.12 Keterkaitan Penelitian 12 16
Tabel 2.13 Sintesis Penelitian Terdahulu 16
Tabel 2.14 Metrik Evaluasi Model 22

BAB 1 PENDAHULUAN

Bab ini menguraikan latar belakang permasalahan kerawanan tanah longsor di Indonesia, rumusan masalah, tujuan, batasan masalah, manfaat, serta relevansi tugas akhir terhadap roadmap Laboratorium Rekayasa Data dan Intelegensi Bisnis (RDIB) dan mata kuliah Pemodelan dan Analitika Prediktif (PAP 1).

1.1 Latar Belakang

Indonesia merupakan salah satu negara dengan tingkat kerawanan bencana alam yang tinggi. Kondisi geografis Indonesia yang berada pada pertemuan lempeng tektonik, topografi yang beragam, serta iklim tropis dengan curah hujan tinggi menyebabkan wilayah Indonesia rentan terhadap berbagai jenis bencana, khususnya bencana hidrometeorologi. Berdasarkan data Badan Nasional Penanggulangan Bencana (BNPB), banjir dan tanah longsor tercatat sebagai dua jenis bencana alam yang paling sering terjadi di Indonesia (Tempo, 2024). Salah satu bencana yang menimbulkan dampak besar secara konsisten adalah tanah longsor. Berdasarkan data GIS BNPB, sepanjang tahun 2024 tercatat 212 kejadian tanah longsor di berbagai wilayah Indonesia. Pada tahun yang sama, BNPB juga menyebut tanah longsor sebagai bencana paling mematikan di Indonesia, salah satunya dipengaruhi oleh kejadian longsor di Pertambangan Rakyat, Bone Bolango, Gorontalo (Mufarida, 2024). Pada tahun 2025, jumlah kejadian tanah longsor meningkat menjadi 246 kejadian. Data tersebut menunjukkan bahwa tanah longsor masih menjadi ancaman serius yang menimbulkan korban jiwa dan kerusakan infrastruktur, sehingga diperlukan upaya mitigasi yang lebih baik dan lebih terarah.

Dalam praktiknya, penanggulangan bencana tanah longsor di Indonesia masih cenderung didominasi oleh respons setelah kejadian terjadi, sehingga pendekatan prediktif dan preventif perlu diperkuat. Faktanya, tanah longsor dipengaruhi oleh berbagai faktor yang dapat diukur dan dianalisis, seperti curah hujan, kemiringan lereng, jenis tanah, elevasi, tutupan lahan, dan kelembapan tanah. Ketersediaan data dari faktor-faktor tersebut membuka peluang untuk mengembangkan pendekatan prediktif berbasis data yang mampu membantu identifikasi tingkat kerawanan tanah longsor pada suatu wilayah.

Salah satu pendekatan yang dapat digunakan untuk mendukung hal tersebut adalah *machine learning*. Metode *machine learning* mampu mempelajari pola hubungan antara faktor-faktor pemicu tanah longsor dan kejadian longsor berdasarkan data historis. Berbagai penelitian terdahulu menunjukkan bahwa algoritma *machine learning* seperti Random Forest dan XGBoost memiliki performa yang baik dalam analisis kerentanan tanah longsor (Merghadi et al., 2020). Melalui pendekatan ini, model dapat digunakan untuk memprediksi kelas kerawanan tanah longsor dan mengklasifikasikannya ke dalam kategori tertentu, sehingga informasi yang dihasilkan menjadi lebih mudah dipahami dan dimanfaatkan oleh pengguna.

Namun, performa model *machine learning* tidak hanya dipengaruhi oleh algoritma yang digunakan, tetapi juga oleh kualitas fitur yang dipilih sebagai masukan model dan konfigurasi hyperparameter yang diterapkan. Tidak semua fitur memiliki kontribusi yang sama terhadap hasil klasifikasi. Beberapa fitur dapat memberikan pengaruh yang signifikan, sedangkan fitur lain mungkin kurang relevan atau justru menurunkan performa model. Oleh karena itu, *feature selection* diperlukan untuk memilih fitur-fitur yang paling relevan agar model dapat bekerja secara lebih efektif dan efisien. Di sisi lain, *hyperparameter tuning* juga menjadi tahapan

penting karena pengaturan parameter yang kurang tepat dapat menyebabkan performa model belum optimal.

Proses optimasi *feature selection* dan *hyperparameter tuning* secara manual maupun dengan metode konvensional seperti *Grid Search* memiliki keterbatasan dalam hal efisiensi dan cakupan ruang pencarian. Pada permasalahan dengan kombinasi fitur dan parameter yang kompleks, pendekatan tersebut cenderung memerlukan waktu yang lebih lama dan belum tentu menghasilkan solusi terbaik. Oleh karena itu, dibutuhkan metode optimasi yang mampu mengeksplorasi ruang solusi secara lebih luas dan adaptif.

Salah satu pendekatan yang dapat digunakan adalah metode optimasi metaheuristik. Metode metaheuristik mampu mengeksplorasi ruang solusi secara lebih luas dan adaptif dibandingkan metode konvensional. *Variable Neighborhood Search* (VNS) merupakan salah satu metode metaheuristik yang diperkenalkan oleh Mladenović dan Hansen (1997), yang bekerja dengan mengeksplorasi berbagai struktur neighborhood secara sistematis untuk menemukan solusi optimal. VNS telah terbukti efektif untuk *feature selection* (Syed, 2023) dan *hyperparameter tuning* (Radomirović et al., 2024) pada model *machine learning*. Dalam tugas akhir ini, VNS digunakan untuk mengoptimalkan *feature selection* dan *hyperparameter tuning* pada model *machine learning* yang digunakan dalam arsitektur *stacking ensemble learning*.

Selain pengembangan model, penyajian hasil klasifikasi dalam bentuk sistem *web* juga menjadi aspek penting agar informasi kerawanan dapat dipahami oleh pengguna dengan lebih mudah. Dalam tugas akhir bersama ini, TERRA dikembangkan sebagai sistem *web* prediksi kerawanan multi-bencana yang mengintegrasikan dua modul, yaitu modul kerawanan tanah longsor dan modul kerawanan banjir. Tugas akhir ini berfokus pada pengembangan modul TERRA-LANDSLIDE, sedangkan modul banjir dikembangkan secara terpisah dalam payung sistem yang sama.

Modul TERRA-LANDSLIDE berfungsi sebagai media penyajian hasil klasifikasi kerawanan tanah longsor secara visual, informatif, dan mudah dipahami. Melalui sistem *web* TERRA, hasil klasifikasi kerawanan tanah longsor dapat ditampilkan dalam bentuk visualisasi, ringkasan wilayah, serta rekomendasi mitigasi berdasarkan kelas kerawanan yang dihasilkan. Dengan demikian, hasil tugas akhir tidak hanya berhenti pada pengembangan model, tetapi juga disajikan dalam bentuk yang lebih aplikatif bagi masyarakat dan instansi terkait.

Berdasarkan kebutuhan tersebut, tugas akhir ini mengembangkan modul klasifikasi kerawanan tanah longsor berbasis *web* pada sistem TERRA menggunakan pendekatan *machine learning*. Proses prediksi dalam tugas akhir ini diformulasikan sebagai permasalahan klasifikasi multi-kelas, yaitu pengelompokan wilayah ke dalam kelas kerawanan rendah, sedang, dan tinggi. Tugas akhir ini menggunakan pendekatan *stacking ensemble learning* yang dioptimasi menggunakan *Variable Neighborhood Search* (VNS) agar diperoleh performa klasifikasi yang lebih baik dibandingkan model tanpa optimasi.

Tugas akhir ini diharapkan dapat memberikan kontribusi sebagai bahan pendukung bagi pemerintah, instansi terkait, dan masyarakat dalam meningkatkan kewaspadaan serta upaya mitigasi terhadap bencana tanah longsor. Selain itu, tugas akhir ini juga diharapkan dapat memberikan kontribusi akademik dalam pengembangan pemanfaatan *machine learning*, *Variable Neighborhood Search*, *stacking ensemble learning*, dan sistem *web* untuk kajian kebencanaan di Indonesia.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Bagaimana membangun sistem web TERRA yang fungsional dengan modul TERRA-LANDSLIDE sebagai salah satu komponennya?
2. Bagaimana membangun model klasifikasi tingkat kerawanan tanah longsor menggunakan pendekatan *stacking ensemble learning* yang dioptimasi dengan Variable Neighborhood Search (VNS) berdasarkan faktor-faktor spasial pemicu longsor?
3. Bagaimana mengintegrasikan hasil klasifikasi kerawanan tanah longsor ke dalam modul TERRA-LANDSLIDE pada sistem web TERRA agar dapat menyajikan visualisasi, ringkasan wilayah, dan rekomendasi mitigasi secara informatif bagi masyarakat dan instansi terkait?

1.3 Batasan Masalah

Agar tugas akhir ini lebih terarah dan fokus, ditetapkan batasan masalah sebagai berikut:

1. Tugas akhir ini difokuskan pada pengembangan modul TERRA-LANDSLIDE untuk klasifikasi kerawanan tanah longsor, sedangkan modul bencana lain dalam sistem TERRA berada di luar ruang lingkup tugas akhir ini.
2. Data yang digunakan mencakup data historis kejadian tanah longsor dari portal GIS BNPB serta data spasial faktor pemicu yang diperoleh dari Google Earth Engine (GEE) dan NASA, untuk periode tahun 2019 hingga 2025. Faktor spasial yang digunakan meliputi curah hujan, kemiringan lereng, elevasi, jenis tanah, tutupan lahan, kelembapan tanah, dan indeks vegetasi.
3. Output model berupa prediksi kelas kerawanan tanah longsor yang diformulasikan sebagai klasifikasi ke dalam tiga kategori, yaitu rendah, sedang, dan tinggi.
4. Visualisasi pada sistem *web* TERRA berfokus pada penyajian hasil klasifikasi kerawanan tanah longsor sesuai cakupan data yang digunakan dalam tugas akhir.
5. Hasil klasifikasi yang ditampilkan pada sistem *web* TERRA merupakan hasil dari data yang tersedia pada periode tugas akhir dengan mempertimbangkan potensi pembaruan data di masa mendatang.
6. Rekomendasi mitigasi yang ditampilkan pada sistem *web* bersifat *rule-based* berdasarkan kelas kerawanan hasil klasifikasi dan tidak menggantikan arahan resmi dari instansi berwenang.
7. Hasil klasifikasi divisualisasikan dalam bentuk *dashboard* berbasis *web* untuk mendukung interpretasi hasil dan tidak dirancang sebagai sistem peringatan dini *real-time* operasional.

1.4 Tujuan

Tujuan dari tugas akhir ini adalah sebagai berikut:

1. Membangun sistem web TERRA yang fungsional dengan modul TERRA-LANDSLIDE sebagai salah satu komponen yang terintegrasi dengan modul TERRA-FLOOD.
2. Membangun model klasifikasi tingkat kerawanan tanah longsor menggunakan pendekatan *stacking ensemble learning* yang dioptimasi dengan Variable

Neighborhood Search (VNS) berdasarkan faktor-faktor spasial pemicu longsor sehingga diperoleh performa klasifikasi yang lebih baik.

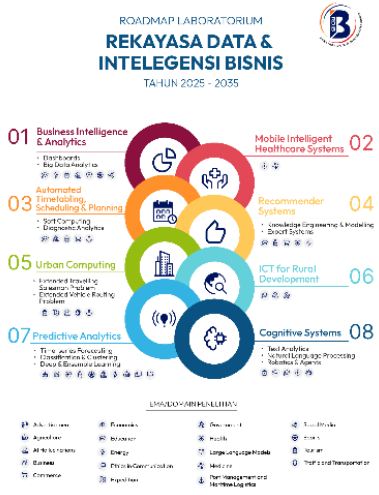
3. Mengintegrasikan hasil klasifikasi kerawanan tanah longsor ke dalam modul TERRA-LANDSLIDE pada sistem web TERRA untuk menampilkan visualisasi, ringkasan wilayah, dan rekomendasi mitigasi berdasarkan kelas kerawanan bagi masyarakat dan instansi terkait.

1.5 Manfaat

Manfaat yang diharapkan dari tugas akhir ini meliputi:

1. Bagi Penulis: Tugas akhir ini memperdalam pemahaman mengenai penerapan *machine learning*, *stacking ensemble learning*, dan Variable Neighborhood Search (VNS) dalam permasalahan klasifikasi kerawanan tanah longsor, serta mengintegrasikan hasilnya ke dalam sistem *web* TERRA.
2. Bagi Masyarakat: Visualisasi hasil prediksi dan klasifikasi tingkat kerawanan tanah longsor dapat membantu meningkatkan pemahaman dan kewaspadaan masyarakat terhadap potensi longsor di wilayah rawan. Rekomendasi mitigasi yang ditampilkan juga dapat memberikan arahan awal mengenai langkah-langkah yang perlu diperhatikan berdasarkan kelas kerawanan wilayah.
3. Bagi Pemerintah dan Instansi Terkait: Hasil tugas akhir ini dapat menjadi bahan pendukung bagi pemerintah daerah atau instansi terkait dalam memahami pola kerawanan longsor, mengidentifikasi wilayah prioritas, serta mendukung penyusunan langkah mitigasi.
4. Bagi Institusi Akademik: Hasil tugas akhir dapat menjadi referensi dan kontribusi keilmuan di bidang *machine learning*, optimasi berbasis Variable Neighborhood Search (VNS), *stacking ensemble learning*, dan pemodelan kerawanan bencana, khususnya yang berkaitan dengan klasifikasi kerawanan tanah longsor.

1.6 Relevansi Tugas Akhir



Gambar 1.1 Roadmap Laboratorium Rekayasa Data dan Intelegensi Bisnis

Tugas akhir ini memiliki relevansi dengan Roadmap Laboratorium Rekayasa Data dan Inteligensi Bisnis tahun 2025–2035, khususnya pada domain Predictive Analytics (07), seperti yang ditunjukkan pada Gambar 1.1. Relevansi tersebut terlihat dari penggunaan pemodelan prediktif berbasis data historis dan faktor spasial untuk mengklasifikasikan tingkat kerawanan tanah longsor ke dalam tiga kelas, yaitu rendah, sedang, dan tinggi. Pendekatan stacking ensemble learning yang dioptimasi menggunakan Variable Neighborhood Search (VNS) juga selaras dengan konsep klasifikasi, ensemble learning, evaluasi performa model, dan optimasi model pada mata kuliah Pemodelan dan Analitika Prediktif (PAP 1).

BAB 2 TINJAUAN PUSTAKA

Bab ini memaparkan dua belas penelitian terdahulu yang relevan serta dasar teori yang menjadi landasan pengembangan TERRA-LANDSLIDE, meliputi konsep tanah longsor, kerawanan bencana, *machine learning*, *stacking ensemble*, *feature selection*, *hyperparameter tuning*, *cross-validation*, Variable Neighborhood Search (VNS), SHAP, metrik evaluasi, dan *web dashboard*.

2.1 Hasil Penelitian Terdahulu

Pada bagian ini disajikan dua belas penelitian terdahulu yang relevan dengan topik tugas akhir, mencakup penerapan *stacking ensemble learning* untuk pemetaan kerawanan longsor, perbandingan algoritma klasifikasi, dan penggunaan VNS sebagai metode optimasi. Setiap penelitian dirangkum berdasarkan jurnal, judul, peneliti, tahun, ringkasan, dan keterkaitannya dengan TERRA-LANDSLIDE.

Tabel 2.1 Keterkaitan Penelitian 1

Jurnal	Applied Sciences (MDPI)
Judul	*Landslide Susceptibility* Mapping Using the *Stacking Ensemble Machine Learning* Method in Lushui, Southwest China
Peneliti	Xudong Hu, Han Zhang, Hongbo Mei, Dunhui Xiao, Yuanyuan Li, Mengdi Li
Publisher	MDPI
Tahun	2020
Ringkasan	Penelitian ini menguji penerapan *stacking ensemble learning* untuk pemetaan kerawanan tanah longsor di Lushui, Tiongkok Barat Daya. Dataset terdiri dari 388 lokasi longsor dan 12 faktor kondisi. Model *base learner* yang digunakan meliputi SVM, ANN, *Logistic Regression*, dan *Naive Bayes*. Hasil penelitian menunjukkan bahwa pendekatan *stacking* mampu meningkatkan performa dibandingkan model tunggal.
Keterkaitan	Penelitian ini menjadi dasar penggunaan *stacking ensemble* pada *TERRA-LANDSLIDE*. Perbedaannya, penelitian ini belum mengintegrasikan optimasi *VNS* untuk *feature selection* dan *hyperparameter tuning*.

Tabel 2.2 Keterkaitan Penelitian 2

Jurnal	Environmental Earth Sciences (Springer)
Judul	*Stacking Ensemble* of *Machine Learning* Methods for *Landslide Susceptibility* Mapping in Zhangjiajie City, Hunan Province, China
Peneliti	Yuke Huan, Lei Song, Umair Khan, Baoyi Zhang
Publisher	Springer Nature
Tahun	2023
Ringkasan	Penelitian ini membandingkan beberapa algoritma *machine learning* untuk pemetaan kerawanan tanah longsor di Zhangjiajie. Tiga *base classifier* yang digunakan adalah RF, GBDT, dan *XGBoost*, kemudian dikombinasikan dengan *Logistic Regression* sebagai *meta-learner*. Model GBDT+LR menghasilkan *AUC* tertinggi sebesar 0,8168.
Keterkaitan	Penelitian ini mendukung penggunaan *stacking* dan menunjukkan bahwa *Logistic Regression* dapat digunakan sebagai *meta-learner*. Strategi pemilihan *base learner* berdasarkan evaluasi performa juga sejalan dengan rancangan *TERRA-LANDSLIDE*.

Tabel 2.3 Keterkaitan Penelitian 3

Jurnal	Geoenvironmental Disasters (Springer Open)
Judul	*Landslide Susceptibility* Assessment of South Korea Using *Stacking Ensemble Machine Learning*
Peneliti	Seung-Min Lee, Seung-Jae Lee, et al.
Publisher	Springer Open
Tahun	2024
Ringkasan	Studi ini melakukan penilaian kerawanan tanah longsor berskala nasional di Korea Selatan menggunakan 30 variabel input, mencakup data iklim, faktor topografi, dan faktor lingkungan. Enam belas algoritma dievaluasi, kemudian model dengan performa terbaik digabungkan melalui *stacking ensemble*. *CatBoost* dilaporkan sebagai salah satu model dengan performa terbaik dengan *AUC* sekitar 0,89.
Keterkaitan	Penelitian ini relevan karena memiliki cakupan skala nasional dan menggunakan strategi evaluasi banyak model sebelum membangun *stacking ensemble*. Pendekatan tersebut serupa dengan strategi *TERRA-LANDSLIDE* yang menguji beberapa kandidat model terlebih dahulu.

Tabel 2.4 Keterkaitan Penelitian 4

Jurnal	Geocarto International (Taylor & Francis)
Judul	Comparative Analysis of Gradient Boosting Algorithms for *Landslide Susceptibility* Mapping
Peneliti	Emrehan Kutlug Sahin
Publisher	Taylor & Francis
Tahun	2022
Ringkasan	Studi ini membandingkan empat algoritma *gradient boosting*, yaitu GBM, *CatBoost*, *XGBoost*, dan *LightGBM*, serta *Random Forest* untuk pemodelan kerawanan tanah longsor. Evaluasi dilakukan menggunakan *AUC*, akurasi, dan *kappa index*. Hasil penelitian memperlihatkan bahwa algoritma *boosting* memiliki performa kompetitif pada pemetaan kerawanan longsor.
Keterkaitan	Penelitian ini mendukung pemilihan beberapa algoritma *boosting* sebagai kandidat model, seperti *XGBoost*, GBM, *LightGBM*, dan *CatBoost*. Temuan ini memperkuat rancangan pengujian model individual pada *TERRA-LANDSLIDE*.

Tabel 2.5 Keterkaitan Penelitian 5

Jurnal	Geocarto International (Taylor & Francis)
Judul	Ensemble *Stacking*: A Powerful Tool for *Landslide Susceptibility* Assessment - A Case Study in Anhua County, Hunan Province, China
Peneliti	Lei-Lei Liu, Aasim Danish, Xiao-Mi Wang, Wen-Qing Zhu
Publisher	Taylor & Francis
Tahun	2024
Ringkasan	Penelitian ini menggunakan pendekatan *stacking* dua lapis dengan *XGBoost*, RF, dan GBDT sebagai *base classifier*, serta Support Vector Classifier (SVC) sebagai *meta-classifier*. Model XGB+SVC memperoleh *AUC* tertinggi sebesar 0,9468 dan seluruh model *stacking* mengungguli model individual.
Keterkaitan	Penelitian ini menunjukkan bahwa pemilihan *meta-learner* berpengaruh terhadap performa *stacking*. Oleh karena itu, *TERRA-LANDSLIDE* membandingkan beberapa kandidat *meta-learner*, termasuk *Logistic Regression*, SVC, dan *LightGBM*.

Tabel 2.6 Keterkaitan Penelitian 6

Jurnal	International Journal of Digital Earth (Taylor & Francis)
Judul	*Landslide Susceptibility* Mapping Using Ensemble *Machine Learning* Methods: A Case Study in Lombardy, Northern Italy
Peneliti	Qiongjie Xu, Vasil Yordanov, Lorenzo Amici, Maria A. Brovelli
Publisher	Taylor & Francis
Tahun	2024
Ringkasan	Studi ini membandingkan tiga teknik *ensemble* heterogen, yaitu *stacking*, *blending*, dan *soft voting* untuk pemetaan kerawanan tanah longsor di Lombardy, Italia Utara. Beberapa *base classifier* yang digunakan meliputi Bagging, RF, *AdaBoost*, Gradient Tree Boosting, dan Neural Network, dengan *Logistic Regression* sebagai *meta-classifier*.
Keterkaitan	Penelitian ini mendukung pemilihan *stacking ensemble* sebagai arsitektur utama karena *stacking* dapat dibandingkan dengan teknik *ensemble* lain dan terbukti kompetitif untuk pemetaan kerawanan longsor.

Tabel 2.7 Keterkaitan Penelitian 7

Jurnal	Geomatics, Natural Hazards and Risk (Taylor & Francis)
Judul	*Landslide Susceptibility* Assessment Through Multi-Model *Stacking* and Meta-Learning in Poyang County, China
Peneliti	Yong Song, Yingxu Song, Chengnan Wang, Linwei Wu, Weicheng Wu, Yuan Li, Sicheng Li, Aiqing Chen
Publisher	Taylor & Francis
Tahun	2024
Ringkasan	Penelitian ini mengevaluasi model individual dan beberapa teknik *ensemble* seperti *stacking*, *voting*, dan *meta-learning* untuk penilaian kerawanan longsor di Poyang, Tiongkok. RF, *LightGBM*, dan MLP digunakan sebagai model dasar, kemudian hasil prediksinya digabungkan melalui *meta-learning*.
Keterkaitan	Penelitian ini relevan karena menerapkan strategi seleksi bertahap: model individual diuji terlebih dahulu, kemudian model terbaik digabungkan. Strategi ini diadopsi dalam *TERRA-LANDSLIDE* untuk menentukan *base learner* dan *meta-learner* secara empiris.

Tabel 2.8 Keterkaitan Penelitian 8

Jurnal	Frontiers in Environmental Science
Judul	Quantitative Evaluation of Uncertainty and Interpretability in *Machine Learning*-Based *Landslide Susceptibility* Mapping Through *Feature Selection* and *Explainable AI*
Peneliti	Xuan-Hien Le, Chanul Choi, Song Eu, Minho Yeon, Giha Lee
Publisher	Frontiers Media
Tahun	2024
Ringkasan	Penelitian ini membandingkan beberapa algoritma *machine learning* seperti RF, *LightGBM*, *XGBoost*, KNN, dan SVM untuk pemetaan kerawanan longsor. Penelitian ini juga menggunakan *feature selection* dan *Explainable AI* berbasis *SHAP* untuk meningkatkan interpretabilitas model.
Keterkaitan	Penelitian ini mendukung pentingnya *feature selection* dan interpretasi model. Hal tersebut relevan dengan *TERRA-LANDSLIDE* yang menggunakan *VNS* untuk seleksi fitur dan *SHAP* untuk analisis kontribusi fitur.

Tabel 2.9 Keterkaitan Penelitian 9

Jurnal	Earth-Science Reviews (Elsevier)
Judul	*Machine Learning* Methods for *Landslide Susceptibility* Studies: A Comparative Overview of Algorithm Performance
Peneliti	Abdelaziz Merghadi, Ali P. Yunus, Jie Dou, et al.
Publisher	Elsevier
Tahun	2020
Ringkasan	Studi tinjauan sistematis ini menganalisis lebih dari 500 publikasi terkait penggunaan *machine learning* untuk studi kerawanan tanah longsor. Algoritma *ensemble* seperti *Random Forest* dan Gradient Boosting dilaporkan menunjukkan performa yang kuat. Studi ini juga menekankan pentingnya pemilihan fitur dan pengaturan *hyperparameter*.
Keterkaitan	Penelitian ini menjadi landasan umum bahwa *machine learning* dan metode *ensemble* relevan untuk pemetaan kerawanan longsor. Penekanan pada *feature selection* dan *hyperparameter tuning* mendukung penggunaan *VNS* dalam *TERRA-LANDSLIDE*.

Tabel 2.10 Keterkaitan Penelitian 10

Jurnal	Optimization Letters (Springer)
Judul	*Feature Selection* in *Machine Learning* via *Variable Neighborhood Search*
Peneliti	Mujahid N. Syed
Publisher	Springer
Tahun	2023
Ringkasan	Penelitian ini mengajukan kerangka kerja heuristik untuk *feature selection* berbasis *VNS*. Kerangka kerja tersebut bersifat generik dan dapat diterapkan pada metode *supervised machine learning* untuk tugas klasifikasi maupun regresi. Eksperimen menunjukkan bahwa *VNS* dapat membantu meningkatkan generalisasi model melalui pemilihan fitur yang lebih relevan.
Keterkaitan	Penelitian ini menjadi referensi utama penggunaan *VNS* untuk *feature selection* pada *TERRA-LANDSLIDE*. Penelitian ini juga mendukung pemilihan *VNS* sebagai metode optimasi metaheuristik.

Tabel 2.11 Keterkaitan Penelitian 11

Jurnal	Complex & Intelligent Systems (Springer)
Judul	Optimizing Long-Short Term Memory Neural Networks for Electroencephalogram Anomaly Detection Using *Variable Neighborhood Search* with Dynamic Strategy Change
Peneliti	Branislav Radomirović, Nebojša Bačanin, Luka Jovanović, et al.
Publisher	Springer Nature
Tahun	2024
Ringkasan	Penelitian ini mengembangkan modifikasi *VNS* untuk mengoptimasi *hyperparameter* model LSTM pada deteksi anomali EEG. Hasil eksperimen menunjukkan bahwa *VNS* memiliki kemampuan kompetitif sebagai metode optimasi *hyperparameter* dibandingkan beberapa metaheuristik lain.
Keterkaitan	Meskipun domainnya berbeda, penelitian ini mendukung penggunaan *VNS* sebagai metode *hyperparameter tuning*. Prinsip tersebut diterapkan pada *TERRA-LANDSLIDE* untuk mengoptimalkan model dalam arsitektur *stacking*.

Tabel 2.12 Keterkaitan Penelitian 12

Jurnal	Frontiers in Artificial Intelligence
Judul	Integrated Evolutionary Learning: An Artificial Intelligence Approach to Joint Learning of Features and Hyperparameters for Optimized, Explainable *Machine Learning*
Peneliti	Nina de Lacy, Michael J. Ramshaw, J. Nathan Kutz
Publisher	Frontiers Media
Tahun	2022
Ringkasan	Penelitian ini memperkenalkan pendekatan Integrated Evolutionary Learning (IEL) untuk optimasi fitur dan *hyperparameter* secara simultan. Pendekatan ini menunjukkan bahwa penggabungan pemilihan fitur dan optimasi konfigurasi model dapat meningkatkan performa dan interpretabilitas *machine learning*.
Keterkaitan	Penelitian ini relevan karena mendukung konsep optimasi simultan *feature selection* dan *hyperparameter tuning*. Perbedaannya, *TERRA-LANDSLIDE* menggunakan *VNS*, bukan *evolutionary algorithm*, dan diterapkan pada konteks klasifikasi kerawanan tanah longsor dengan *stacking ensemble*.

2.1.1 Sintesis Penelitian Terdahulu

Berdasarkan penelitian terdahulu, terdapat beberapa temuan penting yang menjadi dasar tugas akhir *TERRA-LANDSLIDE*. Pertama, pendekatan *machine learning* telah banyak digunakan dalam pemetaan kerawanan tanah longsor karena mampu mempelajari hubungan nonlinier antara faktor pemicu dan kejadian longsor. Kedua, metode *ensemble*, khususnya *stacking ensemble*, terbukti mampu meningkatkan performa dengan menggabungkan prediksi dari beberapa model. Ketiga, pemilihan fitur dan pengaturan *hyperparameter* menjadi aspek penting yang memengaruhi performa model. Keempat, *VNS* memiliki potensi sebagai metode optimasi untuk *feature selection* dan *hyperparameter tuning*.

Tabel 2.13 Sintesis Penelitian Terdahulu

Aspek	Temuan Utama	Implikasi terhadap *TERRA-LANDSLIDE*
Pemodelan kerawanan longsor	Sebagian besar studi menggunakan *machine learning* untuk memetakan kerawanan tanah longsor berdasarkan data historis dan faktor kondisi.	Tugas akhir ini menggunakan data historis longsor dan data spasial sebagai dasar klasifikasi kerawanan.
Pemilihan model	Penelitian terdahulu menunjukkan bahwa RF, *XGBoost*, *LightGBM*, *CatBoost*, SVM, KNN, LR, ANN, dan beberapa model *ensemble* sering digunakan.	Tugas akhir ini menguji 13 kandidat model individual sebelum menentukan komponen *stacking*.
Arsitektur *stacking*	Beberapa studi menunjukkan bahwa *stacking* dapat mengungguli model tunggal, tetapi performanya dipengaruhi oleh pemilihan *base learner* dan *meta-learner*.	Tugas akhir ini memilih *base learner* dan *meta-learner* berdasarkan hasil evaluasi empiris.
Optimasi model	*Feature selection* dan *hyperparameter tuning* terbukti penting untuk meningkatkan performa dan generalisasi model.	Tugas akhir ini menggunakan *VNS* untuk mengoptimalkan seleksi fitur dan *hyperparameter tuning*.
Interpretasi model	*SHAP* digunakan untuk menjelaskan kontribusi fitur dan meningkatkan interpretabilitas model.	Tugas akhir ini menggunakan *SHAP* untuk menganalisis faktor yang berpengaruh terhadap hasil klasifikasi.

Dengan demikian, celah tugas akhir yang diambil adalah pengembangan modul *TERRA-LANDSLIDE* yang mengombinasikan *stacking ensemble learning* dengan optimasi *VNS* untuk menghasilkan klasifikasi kerawanan tanah longsor yang dapat diintegrasikan ke dalam sistem web *TERRA*.

2.2 Dasar Teori

Bagian dasar teori membahas konsep-konsep utama yang menjadi landasan dalam tugas akhir ini. Teori yang digunakan mencakup tanah longsor, kerawanan bencana, klasifikasi kerawanan, *machine learning*, kandidat algoritma, *feature selection*, *hyperparameter tuning*, *cross-validation*, *stacking ensemble learning*, Variable Neighborhood Search (VNS), SHAP, metrik evaluasi, *web dashboard* visualisasi, serta rekomendasi mitigasi berbasis aturan. Teori-teori tersebut digunakan untuk mendukung pengembangan TERRA-LANDSLIDE sebagai sistem klasifikasi kerawanan tanah longsor berbasis web dengan pendekatan *VNS-optimized stacking ensemble learning*.

2.2.1 Tanah Longsor

Tanah longsor merupakan peristiwa perpindahan massa tanah, batuan, atau material penyusun lereng ke arah bawah yang dipengaruhi oleh gaya gravitasi. Peristiwa ini umumnya terjadi ketika kestabilan lereng terganggu akibat kombinasi faktor alami maupun aktivitas manusia. Faktor yang sering memengaruhi kejadian tanah longsor antara lain curah hujan, kemiringan lereng, elevasi, jenis tanah, tutupan lahan, kondisi geologi, kelembapan tanah, serta perubahan penggunaan lahan (Cruden & Varnes, 1996; BNPB, 2019).

Dalam konteks kebencanaan di Indonesia, tanah longsor termasuk salah satu bencana yang sering terjadi pada wilayah dengan topografi berbukit atau bergunung, intensitas hujan tinggi, dan kondisi lereng yang tidak stabil. Oleh karena itu, pemahaman terhadap faktor-faktor pemicu tanah longsor penting digunakan sebagai dasar dalam pemodelan kerawanan wilayah.

2.2.2 Kerawanan Bencana

Kerawanan bencana menunjukkan kecenderungan suatu wilayah untuk mengalami bencana berdasarkan kondisi fisik, lingkungan, dan faktor pemicu tertentu. Dalam tugas akhir ini, istilah kerawanan digunakan untuk menggambarkan potensi atau kecenderungan suatu wilayah mengalami tanah longsor berdasarkan data historis dan faktor spasial pendukung. Kerawanan berbeda dengan risiko karena risiko umumnya melibatkan komponen yang lebih luas, seperti paparan, kerentanan sosial, kapasitas, dan potensi kerugian.

Pada konteks *landslide susceptibility*, kerawanan tanah longsor mengacu pada kemungkinan relatif suatu wilayah mengalami longsor berdasarkan karakteristik lingkungan dan kejadian historis. Pemodelan kerawanan tidak bertujuan memprediksi waktu pasti terjadinya longsor, tetapi mengidentifikasi wilayah yang memiliki kecenderungan lebih tinggi untuk mengalami longsor (Guzzetti et al., 2006; Reichenbach et al., 2018).

2.2.3 Klasifikasi Kerawanan Tanah Longsor

Klasifikasi kerawanan tanah longsor merupakan proses pengelompokan wilayah ke dalam kategori tertentu berdasarkan tingkat kerawanannya. Dalam tugas akhir ini, kelas kerawanan dibagi menjadi tiga kategori, yaitu rendah, sedang, dan tinggi. Pembagian kelas tersebut digunakan agar hasil model lebih mudah dipahami dan dapat ditampilkan secara informatif pada dashboard TERRA-LANDSLIDE.

Secara teknis, klasifikasi kerawanan tanah longsor diformulasikan sebagai permasalahan *supervised learning*. Model dilatih menggunakan data historis dan fitur-fitur pemicu longsor, kemudian mempelajari pola hubungan antara fitur masukan dan label kelas kerawanan. Hasil akhir model berupa prediksi kelas kerawanan suatu wilayah berdasarkan karakteristik spasial dan lingkungan yang tersedia.

2.2.4 Machine Learning

Machine learning merupakan cabang dari kecerdasan buatan yang memungkinkan sistem mempelajari pola dari data dan menghasilkan prediksi atau keputusan tanpa perlu diprogram secara eksplisit untuk setiap aturan (Mitchell, 1997). Dalam tugas akhir kebencanaan, *machine learning* banyak digunakan karena mampu menangkap hubungan kompleks dan nonlinier antara faktor pemicu bencana dan kejadian historis.

Pada tugas akhir ini, *machine learning* digunakan untuk membangun model klasifikasi kerawanan tanah longsor. Model mempelajari hubungan antara variabel masukan, seperti curah hujan, kemiringan lereng, elevasi, tutupan lahan, jenis tanah, kelembapan tanah, dan indeks vegetasi, terhadap kelas kerawanan tanah longsor. Beberapa penelitian terdahulu menunjukkan bahwa metode *machine learning*, terutama model berbasis *ensemble*, memiliki performa yang baik dalam studi *landslide susceptibility mapping* (Merghadi et al., 2020; Lee et al., 2024).

2.2.5 Feature Selection

Feature selection merupakan proses pemilihan subset fitur yang paling relevan dari keseluruhan fitur yang tersedia. Proses ini penting karena tidak semua fitur memberikan kontribusi yang sama terhadap performa model. Fitur yang tidak relevan, redundan, atau terlalu banyak dapat meningkatkan kompleksitas model, memperbesar risiko *overfitting*, dan menurunkan kemampuan generalisasi model (Guyon & Elisseeff, 2003).

Secara umum, metode *feature selection* dapat dibagi menjadi tiga pendekatan, yaitu *filter*, *wrapper*, dan *embedded*. Metode *filter* menilai fitur berdasarkan ukuran statistik tanpa melibatkan model prediksi. Metode *wrapper* mengevaluasi subset fitur berdasarkan performa model. Sementara itu, metode *embedded* melakukan seleksi fitur sebagai bagian dari proses pelatihan model. Tugas akhir ini menggunakan pendekatan *wrapper* berbasis VNS karena setiap kombinasi fitur dievaluasi berdasarkan performa model klasifikasi yang dihasilkan (Syed, 2023).

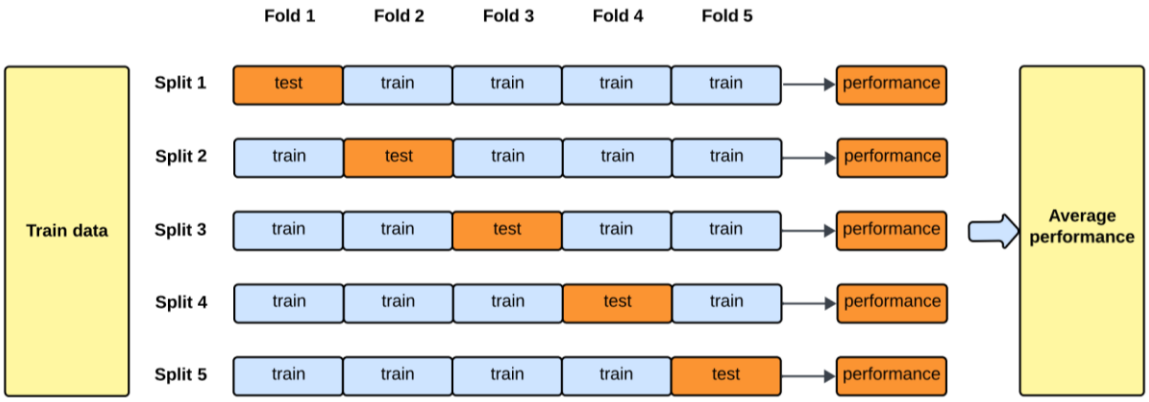
2.2.6 Hyperparameter Tuning

Hyperparameter merupakan parameter yang nilainya ditentukan sebelum proses pelatihan model dan tidak dipelajari langsung dari data. Contoh *hyperparameter* antara lain jumlah pohon pada *Random Forest, learning rate* pada model *boosting*, nilai *max depth*, jumlah tetangga pada KNN, serta parameter C dan gamma pada SVM. Pemilihan *hyperparameter* yang kurang tepat dapat menyebabkan model memiliki performa yang belum optimal.

Hyperparameter tuning adalah proses pencarian konfigurasi *hyperparameter* terbaik untuk meningkatkan performa model. Metode konvensional seperti *Grid Search* dan *Random Search* dapat digunakan, tetapi metode tersebut memiliki keterbatasan ketika ruang pencarian menjadi besar. Oleh karena itu, metode optimasi metaheuristik seperti VNS dapat digunakan untuk melakukan pencarian konfigurasi model secara lebih adaptif dan efisien (Bergstra & Bengio, 2012; Radomirović et al., 2024).

2.2.7 Cross-Validation 5-Fold

Cross-validation merupakan teknik evaluasi model yang digunakan untuk memperoleh estimasi performa yang lebih stabil dan tidak bergantung pada satu pembagian data tertentu. Pada metode *k-fold cross-validation*, dataset dibagi menjadi k bagian atau *fold* yang sama besar. Model dilatih sebanyak k kali, dengan setiap *fold* secara bergantian digunakan sebagai data validasi, sedangkan *fold* lainnya digunakan sebagai data pelatihan. Metrik evaluasi kemudian dihitung dari rata-rata seluruh iterasi sehingga menghasilkan estimasi performa yang lebih representatif (James et al., 2013).



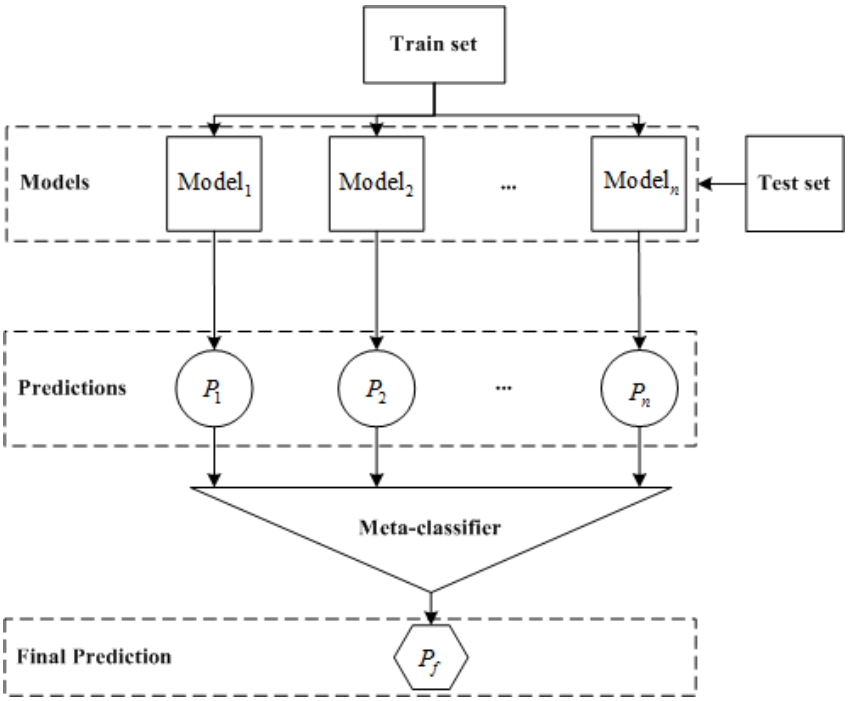
Gambar 2.1 Ilustrasi *Stratified 5-Fold Cross-Validation*

Tugas akhir ini menggunakan *Stratified 5-Fold Cross-Validation*, dataset dibagi menjadi 5 *fold* dengan proporsi kelas yang seimbang pada setiap *fold*, seperti yang diilustrasikan pada Gambar 2.1. Nilai k=5 dipilih karena menyeimbangkan antara bias dan varians estimasi performa serta lebih efisien secara komputasi (James et al., 2013). Stratifikasi diterapkan untuk memastikan proporsi kelas rendah, sedang, dan tinggi tetap terjaga pada setiap *fold*, mengingat distribusi kelas pada dataset penelitian ini tidak seimbang.

Cross-validation digunakan pada dua tahap dalam tugas akhir ini. Pertama, digunakan untuk mengevaluasi dan meranking seluruh kandidat algoritma *machine learning* secara individual. Kedua, digunakan sebagai fungsi evaluasi dalam proses optimasi VNS, setiap solusi kandidat VNS dievaluasi menggunakan *Stratified 5-Fold Cross-Validation* untuk memperoleh nilai F1-*score weighted* yang digunakan sebagai fungsi objektif.

2.2.8 Stacking Ensemble Learning

Stacking ensemble learning merupakan metode *ensemble learning* yang menggabungkan beberapa model dasar (*base learner*) melalui model tingkat atas yang disebut *meta-learner*. Konsep ini pertama kali diperkenalkan oleh Wolpert (1992) sebagai *stacked generalization*, dengan ide dasar bahwa kombinasi beberapa model yang beragam dapat menghasilkan prediksi yang lebih baik dibandingkan model tunggal manapun.



Gambar 2.2 Arsitektur *stacking ensemble learning* (Jiang et al., 2019)

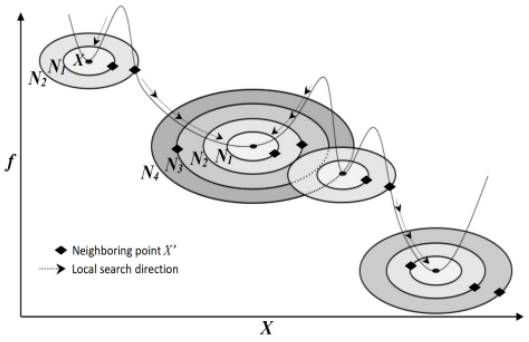
Arsitektur *stacking ensemble learning* terdiri dari dua lapisan utama seperti yang diilustrasikan pada Gambar 2.2. Lapisan pertama adalah lapisan *base learner*, beberapa model dengan algoritma yang berbeda dilatih secara paralel menggunakan data training yang sama. Prediksi dari setiap *base learner* kemudian dikumpulkan dan digunakan sebagai fitur masukan baru untuk lapisan kedua, yaitu *meta-learner*. *Meta-learner* bertugas mempelajari cara terbaik untuk menggabungkan prediksi dari seluruh *base learner* untuk menghasilkan prediksi akhir (Wolpert, 1992; Jiang et al., 2019).

Keunggulan *stacking* dibandingkan metode *ensemble* lain seperti *bagging* dan *boosting* terletak pada kemampuannya menggabungkan model-model dengan karakteristik pembelajaran yang berbeda. *Bagging* dan *boosting* umumnya menggunakan satu jenis algoritma dasar yang diulang, sedangkan *stacking* memungkinkan kombinasi algoritma yang beragam sehingga setiap model dapat saling melengkapi dalam menangkap pola yang berbeda dari data (Mienye & Sun, 2022).

Dalam tugas akhir ini, kandidat *base learner* dan *meta-learner* ditentukan secara empiris melalui pengujian dan perankingan beberapa algoritma *machine learning* berdasarkan nilai F1-*score* dari *Stratified 5-Fold Cross-Validation*. Arsitektur *stacking* yang telah terbentuk kemudian dioptimasi menggunakan Variable Neighborhood Search (VNS) untuk meningkatkan performa klasifikasi kerawanan tanah longsor.

2.2.9 Variable Neighborhood Search (VNS)

Variable Neighborhood Search (VNS) merupakan metode optimasi metaheuristik yang diperkenalkan oleh Mladenović dan Hansen (1997). Prinsip utama VNS adalah mengeksplorasi beberapa struktur *neighborhood* secara sistematis untuk mencari solusi yang lebih baik. Solusi yang menjadi optimum lokal pada satu struktur *neighborhood* belum tentu menjadi optimum lokal pada struktur *neighborhood* lain, sehingga perpindahan antar-*neighborhood* dapat membantu proses pencarian keluar dari jebakan *local optimum* (Mladenović & Hansen, 1997).



(a) Searching process.

```
procedure VNS( f, MaxIter, k_max )
1   Solution ← Ø
2   for i=1,MaxIter:
3       randomly generate X                      //initial point
4       k ← 1
5       while k ≤ k_max:
6           randomly generate X' ∈ N_k(X)        //shaking
7           X"← local_search(X')
8           if f(X") better than f(X):
9               X ← X"                           //make a move
10              k ← 1                            //back to first neihgborhood
11          else:
12              k ← k + 1                        //next neighborhood
13      Sol ← (x, f(X))
14      Update(Solution, Sol)
15  return Solution
end procedure VNS
```

(b) Pseudocode.

Gambar 2.3 Ilustrasi Algoritma Variable Neighborhood Search (VNS): Proses Pencarian dan Pseudocode. (Pambudi & Kawamura, 2022)

Secara umum, proses VNS terdiri dari tiga tahap utama, yaitu *shaking*, *local search*, dan evaluasi, seperti yang diilustrasikan pada Gambar 2.3. Tahap *shaking* dilakukan dengan memberikan perubahan acak pada solusi saat ini berdasarkan struktur *neighborhood* ke-*k*, sehingga pencarian dapat berpindah ke area yang berbeda dalam ruang solusi (Pambudi & Kawamura, 2022). Tahap *local search* kemudian dilakukan untuk memperbaiki solusi kandidat yang dihasilkan dari tahap *shaking*. Selanjutnya, solusi kandidat dievaluasi berdasarkan fungsi objektif. Jika solusi baru memiliki performa lebih baik dari solusi saat ini, maka solusi tersebut diterima sebagai solusi terbaik sementara dan pencarian kembali ke *neighborhood* pertama. Sebaliknya, jika tidak ada perbaikan, maka nilai *k* ditingkatkan untuk mencoba struktur *neighborhood* yang lebih luas (Mladenović & Hansen, 1997).

Dalam tugas akhir ini, VNS digunakan untuk mengoptimalkan *feature selection* dan *hyperparameter tuning* pada model *stacking ensemble learning* secara simultan. Setiap solusi VNS merepresentasikan kombinasi subset fitur yang digunakan dan konfigurasi *hyperparameter* untuk setiap komponen dalam arsitektur *stacking*. Fungsi objektif yang digunakan adalah nilai F1-*score weighted* yang diperoleh dari evaluasi model *stacking* melalui *Stratified 5-Fold Cross-Validation*. Dengan demikian, VNS tidak berperan sebagai model klasifikasi, melainkan sebagai metode optimasi untuk meningkatkan performa model klasifikasi kerawanan tanah longsor (Syed, 2023; Jovanović et al., 2024).

2.2.10 SHAP dan Interpretasi Model

SHAP atau *SHapley Additive exPlanations* merupakan metode *Explainable AI* yang digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model. SHAP didasarkan pada konsep nilai Shapley dari teori permainan, yaitu pembagian kontribusi setiap fitur terhadap perubahan output prediksi model (Shapley, 1953; Lundberg & Lee, 2017).

Dalam tugas akhir ini, SHAP digunakan setelah model final diperoleh. Tujuannya adalah untuk mengetahui fitur-fitur yang paling berpengaruh terhadap hasil klasifikasi kerawanan tanah longsor. Interpretasi ini penting karena model *ensemble* seperti *stacking* cenderung lebih kompleks dibandingkan model sederhana. Dengan SHAP, hasil model tidak hanya dinilai dari performa numerik, tetapi juga dapat dijelaskan berdasarkan kontribusi faktor pemicu longsor seperti curah hujan, kemiringan lereng, elevasi, tutupan lahan, jenis tanah, dan kelembapan tanah.

2.2.11 Metrik Evaluasi

Metrik evaluasi digunakan untuk menilai performa model klasifikasi. Tugas akhir ini tidak hanya menggunakan akurasi karena akurasi dapat memberikan gambaran yang kurang tepat apabila distribusi kelas tidak seimbang (Mienye & Sun, 2022). Oleh karena itu, beberapa metrik lain digunakan agar performa model dapat dinilai secara lebih komprehensif. Metrik yang digunakan beserta fungsinya disajikan pada Tabel 2.14.

Tabel 2.14 Metrik Evaluasi Model

Metrik	Fungsi
Akurasi	Mengukur proporsi prediksi yang benar terhadap seluruh data uji.
Precision	Mengukur ketepatan model dalam menghasilkan prediksi pada suatu kelas.
Recall	Mengukur kemampuan model dalam mendeteksi seluruh data pada kelas tertentu.
F1-score	Mengukur keseimbangan antara *precision* dan *recall*.
Confusion matrix	Menampilkan distribusi prediksi benar dan salah pada setiap kelas.
Macro-average	Menghitung rata-rata metrik antar kelas tanpa mempertimbangkan jumlah data per kelas.
Weighted-average	Menghitung rata-rata metrik antar kelas dengan mempertimbangkan proporsi jumlah data per kelas.

Confusion matrix merupakan tabel yang merangkum hasil prediksi model terhadap data uji, yaitu baris merepresentasikan kelas aktual dan kolom merepresentasikan kelas prediksi. Nilai pada diagonal utama menunjukkan prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan prediksi yang salah (James et al., 2013). Contoh *confusion matrix* untuk klasifikasi tiga kelas kerawanan ditunjukkan pada Gambar 2.4.



Gambar 2.4 Contoh *Confusion Matrix* Klasifikasi Tiga Kelas Kerawanan

Berdasarkan *confusion matrix*, metrik evaluasi dihitung menggunakan nilai prediksi benar dan salah pada setiap kelas. Untuk setiap kelas secara *one-vs-rest*, nilai *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) diperoleh dari *confusion matrix* tersebut (James et al., 2013).

$$Accuracy = \frac{\sum_i TP_i}{\sum_i (TP_i + FP_i + FN_i + TN_i)}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1\text{-}score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Karena tugas akhir ini menggunakan tiga kelas kerawanan (rendah, sedang, dan tinggi), *F1-score weighted* digunakan sebagai metrik utama dan fungsi objektif dalam proses optimasi VNS karena lebih representatif terhadap distribusi kelas yang tidak seimbang. *F1-score macro* digunakan untuk melihat performa rata-rata antar kelas secara lebih adil tanpa pengaruh proporsi data per kelas (James et al., 2013).

2.2.12 *Web Dashboard* Visualisasi

Web dashboard visualisasi merupakan media penyajian informasi berbasis web yang memungkinkan pengguna melihat hasil analisis secara interaktif dan mudah dipahami. Dalam tugas akhir ini, dashboard TERRA digunakan untuk menampilkan hasil klasifikasi kerawanan tanah longsor pada modul TERRA-LANDSLIDE. Informasi yang ditampilkan meliputi peta kerawanan, ringkasan wilayah, kelas kerawanan, skor probabilitas, faktor dominan, serta rekomendasi mitigasi.

Dashboard berperan sebagai penghubung antara hasil pemodelan teknis dengan kebutuhan pengguna. Hasil model yang semula berupa output numerik atau kelas prediksi dapat disajikan dalam bentuk visual yang lebih informatif. Dengan demikian, pengguna dapat memahami pola kerawanan secara spasial dan memperoleh informasi awal mengenai kondisi wilayah yang dipilih.

2.2.13 Rekomendasi Mitigasi Berbasis Aturan

Rekomendasi mitigasi berbasis aturan atau *rule-based mitigation recommendation* merupakan pendekatan penyajian saran tindakan berdasarkan kondisi atau kategori tertentu yang telah ditentukan sebelumnya. Dalam tugas akhir ini, rekomendasi mitigasi disusun berdasarkan kelas kerawanan hasil klasifikasi, yaitu rendah, sedang, dan tinggi. Setiap kelas dihubungkan dengan arahan umum yang sesuai, seperti pemantauan kondisi lingkungan, peningkatan kewaspadaan saat hujan deras, penghindaran area lereng rawan, dan koordinasi dengan pihak berwenang.

Rekomendasi mitigasi pada dashboard TERRA-LANDSLIDE bersifat informatif dan tidak menggantikan arahan resmi dari instansi berwenang seperti BNPB, BPBD, atau BMKG. Fitur ini bertujuan membantu pengguna memahami makna hasil klasifikasi kerawanan serta memberikan gambaran awal mengenai tindakan mitigasi yang dapat diperhatikan berdasarkan kelas kerawanan wilayah.

BAB 3 METODOLOGI

Bab ini menjabarkan metode yang digunakan dalam pengerjaan tugas akhir, meliputi tahap persiapan, pengembangan model klasifikasi kerawanan tanah longsor, pengembangan dan integrasi sistem web TERRA, evaluasi dan pelaporan, sketsa dashboard TERRA-LANDSLIDE, serta rencana pelaksanaan tugas akhir secara keseluruhan.

3.1 Metode yang Digunakan

Tugas akhir ini menggunakan pendekatan kuantitatif berbasis *machine learning* untuk membangun model klasifikasi kerawanan tanah longsor pada modul TERRA-LANDSLIDE. Proses prediksi dalam tugas akhir ini diformulasikan sebagai permasalahan klasifikasi multi-kelas, yaitu mengelompokkan wilayah ke dalam tiga kelas kerawanan, yaitu rendah, sedang, dan tinggi, berdasarkan faktor-faktor pemicu tanah longsor.

Metode utama yang digunakan dalam tugas akhir ini adalah *stacking ensemble learning*. Metode ini digunakan untuk menggabungkan beberapa model *machine learning* melalui arsitektur *base learner* dan *meta-learner*. Sebelum arsitektur *stacking* dibangun, beberapa algoritma *machine learning* diuji secara individual untuk mengetahui performa awal masing-masing model pada dataset tugas akhir.

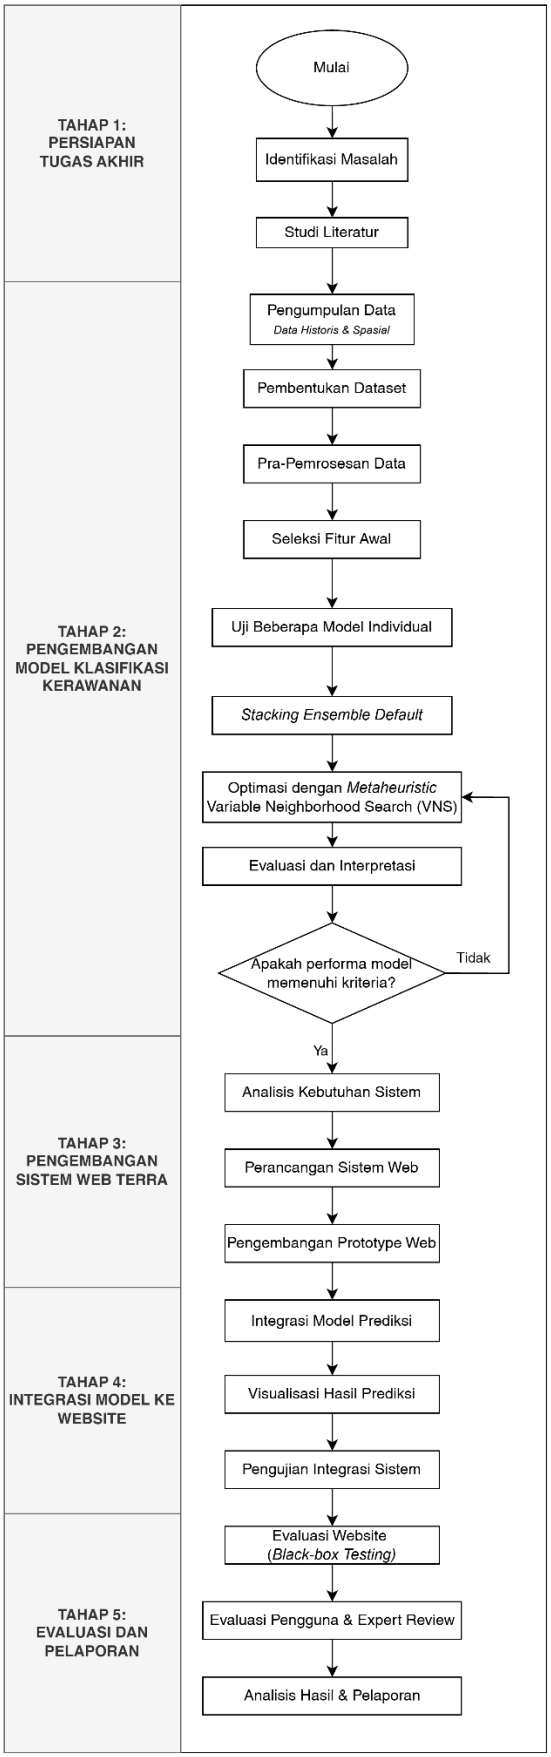
Optimasi model dilakukan menggunakan *Variable Neighborhood Search* (VNS). VNS digunakan untuk mengoptimalkan *feature selection* dan *hyperparameter tuning* pada model *stacking ensemble learning*. Dengan demikian, VNS berperan sebagai metode optimasi untuk mencari kombinasi subset fitur dan konfigurasi *hyperparameter* yang dapat menghasilkan performa klasifikasi yang lebih baik.

Evaluasi model dilakukan dengan membandingkan performa model individual terbaik, *stacking ensemble* default, dan *stacking ensemble* yang telah dioptimasi menggunakan VNS. Metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*. Selain itu, SHAP digunakan untuk menginterpretasikan kontribusi fitur terhadap hasil klasifikasi kerawanan tanah longsor.

Hasil akhir dari tugas akhir ini diintegrasikan ke dalam sistem web TERRA melalui modul TERRA-LANDSLIDE. Sistem web tersebut digunakan untuk menampilkan hasil klasifikasi kerawanan tanah longsor dalam bentuk visualisasi peta, ringkasan wilayah, kelas kerawanan, faktor dominan, dan rekomendasi mitigasi berbasis aturan.

3.2 Alur Pelaksanaan Tugas Akhir

Urutan alur pelaksanaan tugas akhir menjelaskan tahapan yang dilakukan dalam pengembangan TERRA-LANDSLIDE secara sistematis. Alur ini disusun berdasarkan lima tahap utama, yaitu tahap persiapan tugas akhir, pengembangan model klasifikasi kerawanan, pengembangan sistem web TERRA, integrasi model ke website, serta evaluasi dan pelaporan. Setiap tahap memiliki masukan, proses, dan luaran yang menjadi dasar pelaksanaan tahap berikutnya. Alur pelaksanaan tugas akhir ditunjukkan pada Gambar 3.1.



Gambar 3.1 Flowchart Alur Metodologi Tugas Akhir

3.2.1 Identifikasi Masalah

Tahap identifikasi masalah dilakukan untuk menentukan fokus utama tugas akhir. Masukan pada tahap ini berupa kondisi bencana alam di Indonesia, kebutuhan masyarakat terhadap informasi kerawanan bencana yang mudah dipahami, serta kebutuhan sistem berbasis web yang mampu menyajikan hasil klasifikasi kerawanan secara visual.

Pada tahap ini dilakukan perumusan permasalahan terkait klasifikasi kerawanan tanah longsor serta integrasinya ke dalam sistem web TERRA. Proses identifikasi masalah menghasilkan rumusan masalah, tujuan tugas akhir, batasan masalah, dan manfaat tugas akhir. Fokus tugas akhir diarahkan pada pengembangan TERRA-LANDSLIDE sebagai bagian dari sistem web TERRA yang berfungsi untuk mengklasifikasikan tingkat kerawanan tanah longsor berdasarkan faktor-faktor pemicu longsor.

3.2.2 Studi Literatur

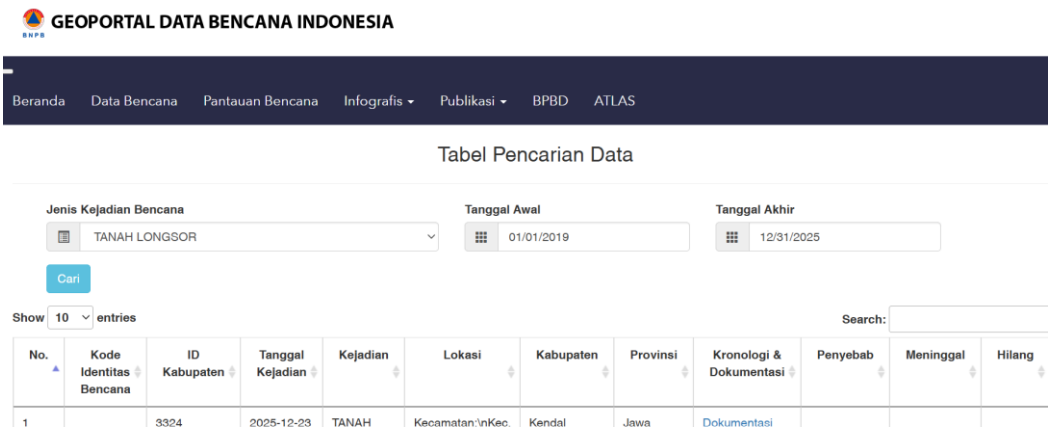
Studi literatur dilakukan untuk memperoleh landasan teori dan referensi penelitian terdahulu yang relevan dengan tugas akhir. Literatur yang dikaji mencakup tanah longsor, kerawanan bencana, klasifikasi kerawanan, *machine learning*, *stacking ensemble learning*, *feature selection*, *hyperparameter tuning*, *Variable Neighborhood Search* (VNS), SHAP, evaluasi model klasifikasi, serta pengembangan dashboard berbasis web.

Hasil studi literatur digunakan sebagai dasar dalam menentukan metode tugas akhir, memilih kandidat algoritma, menyusun rancangan eksperimen model, serta merancang alur pengembangan sistem web TERRA. Luaran dari tahap ini berupa dasar teori, gap penelitian, dan kerangka metode yang digunakan dalam pengembangan TERRA-LANDSLIDE.

3.2.3 Pengumpulan Data

Tahap pengumpulan data dilakukan untuk memperoleh data historis kejadian tanah longsor dan data spasial yang merepresentasikan faktor-faktor pemicu tanah longsor. Data historis kejadian tanah longsor digunakan sebagai dasar pembentukan data kejadian, sedangkan data spasial digunakan untuk membentuk variabel masukan pada model klasifikasi.

Data historis kejadian tanah longsor diperoleh dari portal GIS BNPB. Data yang digunakan mencakup kejadian tanah longsor pada periode 2019 sampai 2025. Pada portal GIS BNPB, data dapat difilter berdasarkan jenis kejadian bencana, yaitu tanah longsor, serta rentang tanggal awal dan tanggal akhir sesuai periode tugas akhir. Hasil filter tersebut kemudian dapat diunduh dan digunakan sebagai data historis kejadian tanah longsor.



Gambar 3.2 Tampilan Filter Data Kejadian Tanah Longsor pada Portal GIS BNPB

Selain data historis kejadian tanah longsor, tugas akhir ini juga menggunakan data spasial yang diperoleh dari sumber data terbuka seperti Google Earth Engine (GEE), NASA, dan sumber spasial pendukung lainnya. Data spasial yang digunakan mencakup faktor-faktor pemicu tanah longsor, seperti curah hujan, elevasi, kemiringan lereng, tutupan lahan, jenis tanah, kelembapan tanah, indeks vegetasi, serta variabel pendukung lain sesuai ketersediaan data.

Luaran dari tahap ini adalah data historis kejadian tanah longsor, data non-longsor atau data pembanding, serta data spasial faktor pemicu yang akan digunakan dalam proses pembentukan dataset.

3.2.4 Pembentukan Dataset

Tahap pembentukan dataset dilakukan dengan menggabungkan data kejadian tanah longsor, data non-longsor, dan data faktor pemicu tanah longsor ke dalam satu dataset terstruktur. Unit analisis yang digunakan disesuaikan dengan kebutuhan pemodelan dan ketersediaan data, misalnya berdasarkan titik kejadian, grid spasial, atau wilayah administratif tertentu.

Pada tahap ini dilakukan ekstraksi nilai fitur spasial dari data sumber ke setiap unit analisis. Setiap titik atau wilayah diberi atribut berupa variabel pemicu, seperti curah hujan, elevasi, kemiringan lereng, tutupan lahan, jenis tanah, kelembapan tanah, dan indeks vegetasi. Selanjutnya, dilakukan proses pelabelan data untuk membentuk target klasifikasi kerawanan tanah longsor.

Luaran dari tahap ini adalah dataset berlabel yang memuat fitur-fitur pemicu tanah longsor dan kelas kerawanan sebagai target model. Dataset ini digunakan sebagai dasar untuk tahap pra-pemrosesan dan pemodelan.

3.2.5 Pra-Pemrosesan Data

Pra-pemrosesan data dilakukan untuk memastikan dataset yang telah dibentuk memiliki format yang sesuai untuk digunakan pada proses pemodelan. Masukan pada tahap ini adalah dataset berlabel dari tahap pembentukan dataset.

Proses pra-pemrosesan meliputi pemeriksaan nilai kosong, penghapusan data duplikat, penyesuaian format data, penyesuaian tipe data, *encoding* fitur kategorikal, serta normalisasi atau standardisasi fitur numerik apabila diperlukan. Setelah itu, dataset dibagi menjadi data latih dan data uji. Pembagian data dilakukan dengan mempertimbangkan distribusi kelas agar proporsi data pada setiap kelas tetap seimbang.

Luaran dari tahap ini adalah dataset training dan dataset testing yang siap digunakan untuk proses seleksi fitur, pengujian model individual, dan pembangunan model *stacking ensemble learning*.

3.2.6 Seleksi Fitur Awal

Seleksi fitur awal dilakukan untuk memperoleh gambaran awal mengenai kontribusi setiap fitur terhadap target klasifikasi. Masukan pada tahap ini berupa dataset training dan daftar fitur faktor pemicu tanah longsor.

Proses seleksi fitur awal dilakukan menggunakan *Random Forest feature importance*. Metode ini digunakan untuk melihat fitur mana yang memiliki pengaruh relatif lebih besar terhadap hasil klasifikasi. Tahap ini bersifat eksploratif dan tidak langsung menjadi hasil akhir pemilihan fitur, karena proses pemilihan subset fitur yang lebih optimal dilakukan pada tahap optimasi menggunakan VNS.

Luaran dari tahap ini adalah daftar kandidat fitur awal yang digunakan sebagai bahan pertimbangan dalam proses pengembangan dan optimasi model.

3.2.7 Uji Beberapa Model Individual

Tahap uji model individual dilakukan untuk mengetahui performa awal dari beberapa algoritma *machine learning* pada dataset tugas akhir. Masukan pada tahap ini berupa dataset training, dataset testing, dan kandidat fitur awal.

Algoritma yang diuji meliputi *Decision Tree*, *Random Forest*, *XGBoost*, *Gradient Boosting Machine*, *LightGBM*, *CatBoost*, *Support Vector Machine*, *K-Nearest Neighbors*, *Logistic Regression*, *Naive Bayes*, *Artificial Neural Network* atau MLP, *AdaBoost*, dan *Bagging Classifier*. Setiap model dilatih dan diuji menggunakan data yang sama agar hasil perbandingan lebih adil.

Luaran dari tahap ini adalah hasil evaluasi awal setiap model individual. Hasil tersebut digunakan untuk mengetahui model yang memiliki performa paling baik dan menjadi dasar pemilihan kandidat model dalam arsitektur *stacking ensemble learning*.

3.2.8 *Stacking Ensemble* Default

Tahap *stacking ensemble* default dilakukan untuk membangun model baseline sebelum proses optimasi. Masukan pada tahap ini berupa hasil evaluasi model individual, kandidat *base learner*, kandidat *meta-learner*, dan dataset training.

Model *stacking ensemble* dibangun dengan menggabungkan beberapa model dasar atau *base learner*. Prediksi dari *base learner* kemudian digunakan sebagai masukan bagi *meta-learner* untuk menghasilkan prediksi akhir. Pada tahap ini, model dibangun tanpa optimasi VNS agar dapat digunakan sebagai pembanding terhadap model yang telah dioptimasi.

Luaran dari tahap ini adalah model *stacking ensemble* baseline beserta nilai performanya.

3.2.9 Optimasi dengan *Metaheuristic*

Optimasi model dilakukan untuk meningkatkan performa *stacking ensemble learning*. Masukan pada tahap ini berupa model *stacking ensemble* baseline, dataset training, daftar fitur, dan ruang pencarian *hyperparameter*.

Pada TERRA-LANDSLIDE, optimasi dilakukan menggunakan *Variable Neighborhood Search* (VNS). VNS digunakan untuk mengoptimalkan *feature selection* dan *hyperparameter tuning* secara bersamaan. Setiap solusi dalam VNS merepresentasikan kombinasi subset fitur dan konfigurasi *hyperparameter*. Proses optimasi dilakukan melalui tahapan *shaking*, *local search*, dan evaluasi fungsi objektif.

Dalam sistem TERRA secara keseluruhan, TERRA-FLOOD menggunakan *Particle Swarm Optimization* (PSO) sebagai metode optimasi. Dengan demikian, tahap optimasi pada sistem TERRA memiliki dua pendekatan berbeda sesuai modul bencana yang dikembangkan. Luaran dari tahap ini adalah model *VNS-optimized stacking classifier* untuk TERRA-LANDSLIDE dan model *PSO-optimized stacking classifier* untuk TERRA-FLOOD.

3.2.10 Evaluasi dan Interpretasi

Evaluasi dilakukan untuk membandingkan performa model individual terbaik, *stacking ensemble* default, dan *stacking ensemble* yang telah dioptimasi. Masukan pada tahap ini berupa model final dan dataset testing.

Metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, *confusion matrix*, *F1-score macro*, dan *F1-score weighted*. Evaluasi ini dilakukan untuk mengetahui apakah proses optimasi mampu meningkatkan performa klasifikasi dibandingkan model sebelum optimasi.

Selain evaluasi performa, interpretasi model dilakukan menggunakan SHAP. SHAP digunakan untuk mengetahui kontribusi masing-masing fitur terhadap hasil prediksi model. Hasil interpretasi ini membantu menjelaskan faktor-faktor dominan yang memengaruhi klasifikasi kerawanan tanah longsor. Luaran dari tahap ini adalah hasil evaluasi model, interpretasi fitur, dan model yang siap diintegrasikan ke dalam sistem web TERRA.

3.2.11 Analisis Kebutuhan Sistem

Tahap analisis kebutuhan sistem dilakukan untuk menentukan kebutuhan fungsional dan non-fungsional dari website TERRA. Masukan pada tahap ini berupa kebutuhan pengguna, tujuan sistem TERRA, hasil studi literatur, serta hasil pengembangan model.

Kebutuhan fungsional mencakup kemampuan pengguna dalam memilih jenis bencana, memilih wilayah, menampilkan hasil prediksi, menampilkan peta kerawanan, menampilkan faktor dominan, serta menampilkan rekomendasi mitigasi. Kebutuhan non-fungsional mencakup kemudahan penggunaan, kejelasan tampilan, keterbacaan informasi, dan waktu respons sistem.

Luaran dari tahap ini adalah daftar kebutuhan sistem dan batasan sistem web TERRA.

3.2.12 Perancangan Sistem Web

Perancangan sistem web dilakukan untuk menyusun struktur dan alur interaksi pengguna pada website TERRA. Masukan pada tahap ini berupa daftar kebutuhan sistem, batasan sistem, dan konsep TERRA sebagai sistem web prediksi kerawanan multi-bencana.

Proses perancangan meliputi penyusunan *user flow*, rancangan fitur utama, desain antarmuka, dan struktur halaman dashboard. Perancangan dilakukan agar pengguna dapat mengakses informasi kerawanan bencana dengan alur yang mudah dipahami.

Luaran dari tahap ini adalah *user flow* TERRA, rancangan fitur, desain antarmuka dashboard, dan struktur halaman sistem.

3.2.13 Pengembangan *Prototype* Web

Pengembangan *prototype* web dilakukan untuk merealisasikan rancangan antarmuka dan fitur utama sistem TERRA. Masukan pada tahap ini berupa rancangan fitur, *user flow*, dan desain antarmuka.

Prototype dikembangkan menggunakan Streamlit sebagai platform pengembangan dashboard berbasis Python. Pada tahap ini dikembangkan halaman input wilayah, halaman dashboard, visualisasi peta, panel hasil prediksi, panel faktor dominan, serta rekomendasi mitigasi. Pada tahap awal, *dummy output* dapat digunakan untuk menguji alur tampilan sebelum model final diintegrasikan.

Luaran dari tahap ini adalah *prototype* sistem web TERRA.

3.2.14 Integrasi Model Prediksi

Integrasi model prediksi dilakukan setelah model final diperoleh. Masukan pada tahap ini berupa model final hasil optimasi, *prototype* website TERRA, dan skenario input pengguna.

Model final diekspor dalam format yang dapat digunakan kembali, seperti *joblib* atau *pickle*. Selanjutnya, model dihubungkan dengan sistem web agar dapat menerima input pengguna, memproses fitur yang diperlukan, dan menghasilkan output prediksi. Proses integrasi mencakup pemanggilan model, penyesuaian format input, pengolahan data, serta pengembalian hasil prediksi ke dashboard.

Luaran dari tahap ini adalah model prediksi yang telah terintegrasi ke dalam sistem web TERRA.

3.2.15 Visualisasi Hasil Prediksi

Visualisasi hasil prediksi dilakukan untuk menyajikan output model dalam bentuk yang lebih informatif. Masukan pada tahap ini berupa hasil prediksi model, data lokasi, dan data pendukung visualisasi.

Visualisasi yang ditampilkan meliputi skor prediksi, kelas kerawanan, peta spasial, faktor dominan, serta rekomendasi mitigasi. Pada modul TERRA-LANDSLIDE, visualisasi digunakan untuk menampilkan hasil klasifikasi kerawanan tanah longsor dalam bentuk dashboard agar pengguna dapat memahami kondisi kerawanan wilayah secara lebih mudah.

Luaran dari tahap ini adalah dashboard prediksi kerawanan, visualisasi peta, dan rekomendasi mitigasi.

3.2.16 Pengujian Integrasi Sistem

Pengujian integrasi sistem dilakukan untuk memastikan koneksi antara model dan website berjalan dengan baik. Masukan pada tahap ini berupa sistem web TERRA yang telah terintegrasi, skenario input pengguna, dan hasil prediksi model.

Proses pengujian dilakukan dengan memeriksa alur input-output, pemanggilan model, tampilan hasil prediksi, visualisasi peta, dan kesesuaian informasi yang ditampilkan pada dashboard. Tahap ini penting untuk memastikan bahwa sistem tidak hanya berjalan secara tampilan, tetapi juga dapat memproses dan menampilkan hasil model dengan benar.

Luaran dari tahap ini adalah hasil pengujian integrasi dan sistem web yang siap dievaluasi pada tahap berikutnya.

3.2.17 Evaluasi Website (*Black-box Testing)*

Evaluasi website dilakukan menggunakan metode *black-box testing*. Masukan pada tahap ini berupa sistem web TERRA, skenario pengujian, dan kebutuhan fungsional sistem.

Pengujian dilakukan dengan memeriksa fungsi utama sistem tanpa melihat kode program secara langsung. Fungsi yang diuji meliputi pemilihan jenis bencana, pemilihan wilayah, proses prediksi, tampilan dashboard, visualisasi peta, panel hasil prediksi, serta rekomendasi mitigasi. Luaran dari tahap ini adalah hasil evaluasi fungsional website yang menunjukkan apakah fitur sistem telah berjalan sesuai kebutuhan.

3.2.18 Evaluasi Pengguna dan *Expert Review*

Evaluasi pengguna dan *expert review* dilakukan untuk menilai kualitas penggunaan dan kesesuaian informasi yang ditampilkan pada sistem. Masukan pada tahap ini berupa sistem web TERRA, kuesioner evaluasi, calon pengguna, dan pakar.

Evaluasi pengguna dilakukan untuk menilai kemudahan penggunaan, kejelasan informasi, dan kenyamanan antarmuka dashboard. Sementara itu, *expert review* dilakukan untuk

memperoleh masukan dari pihak yang memahami bidang kebencanaan, geospasial, atau *machine learning*. Luaran dari tahap ini adalah hasil *usability testing*, masukan pakar, dan rekomendasi perbaikan sistem.

3.2.19 Analisis Hasil dan Pelaporan

Tahap analisis hasil dan pelaporan dilakukan untuk menyusun kesimpulan dari seluruh proses tugas akhir. Masukan pada tahap ini berupa hasil evaluasi model, hasil evaluasi website, masukan pengguna, dan masukan pakar.

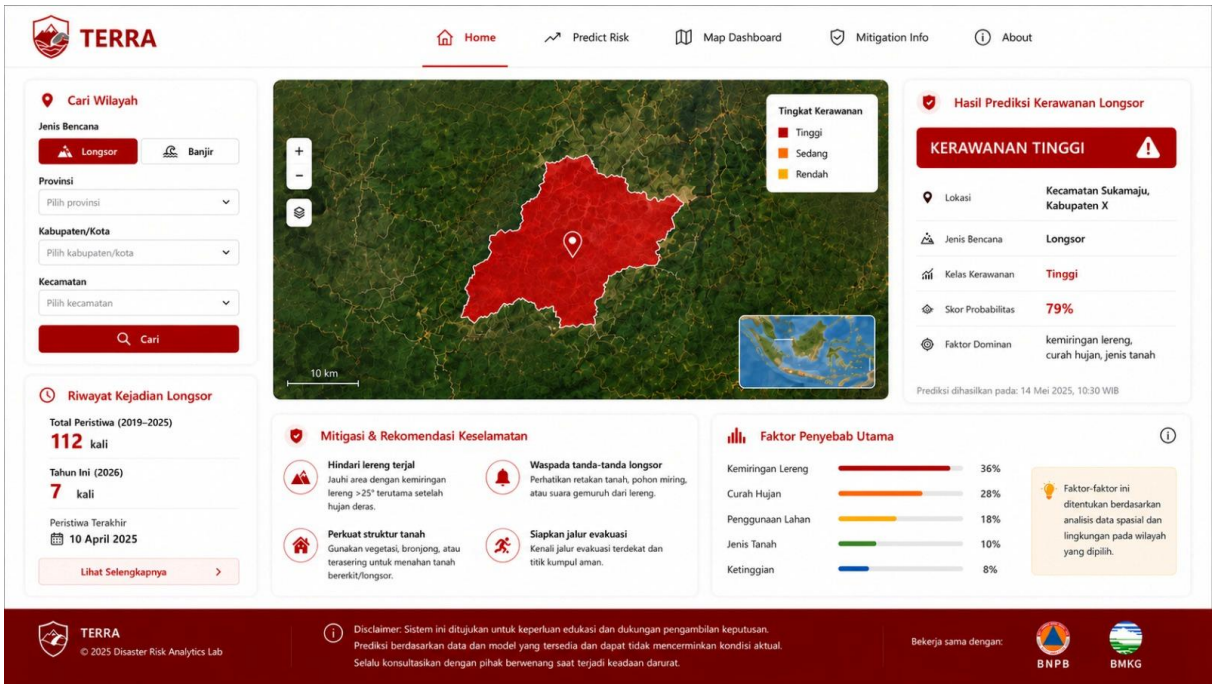
Proses analisis dilakukan untuk menilai keberhasilan model, implementasi sistem, dan kesesuaian hasil tugas akhir terhadap rumusan masalah. Hasil analisis kemudian digunakan untuk menyusun kesimpulan dan saran. Luaran akhir dari tahap ini adalah buku tugas akhir yang memuat seluruh proses tugas akhir, mulai dari pendahuluan, tinjauan pustaka, metodologi, hasil dan pembahasan, hingga kesimpulan dan saran.

3.3 Sketsa Dashboard Website TERRA

Sketsa dashboard website TERRA dirancang untuk menggambarkan tampilan awal sistem yang akan digunakan dalam menyajikan hasil klasifikasi kerawanan bencana. Dashboard ini berfungsi sebagai media visualisasi hasil prediksi model agar informasi kerawanan dapat ditampilkan secara lebih informatif, interaktif, dan mudah dipahami oleh pengguna. Secara umum, dashboard TERRA terdiri atas beberapa komponen utama, yaitu panel pencarian wilayah, pilihan jenis bencana, visualisasi peta kerawanan, kartu hasil prediksi, riwayat kejadian bencana, faktor penyebab utama, serta rekomendasi mitigasi berbasis aturan.

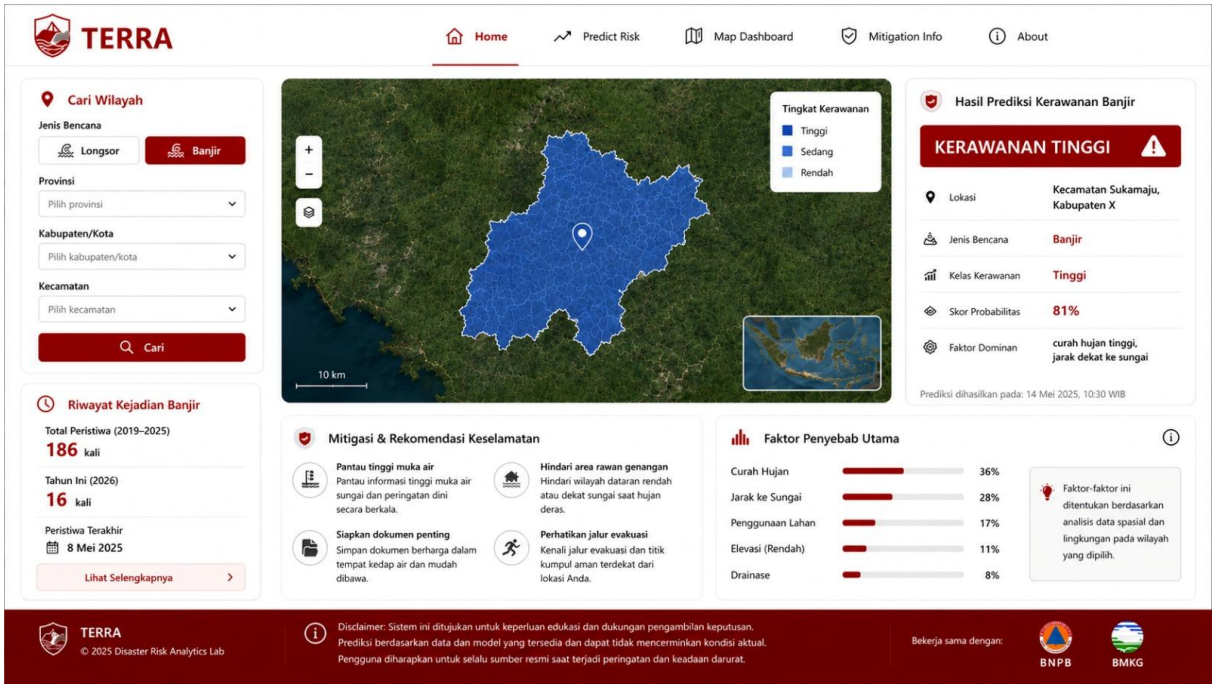
Pada tugas akhir ini, dashboard TERRA dikembangkan untuk mengakomodasi dua modul, yaitu TERRA-LANDSLIDE dan TERRA-FLOOD. Modul TERRA-LANDSLIDE berfokus pada penyajian hasil klasifikasi kerawanan tanah longsor, sedangkan modul TERRA-FLOOD berfokus pada penyajian hasil klasifikasi kerawanan banjir. Meskipun kedua modul berada dalam satu sistem web yang sama, masing-masing modul memiliki karakteristik tampilan, faktor dominan, dan rekomendasi mitigasi yang disesuaikan dengan jenis bencana yang diprediksi.

Sketsa dashboard TERRA-LANDSLIDE ditunjukkan pada Gambar 3.3. Pada tampilan ini, pengguna dapat memilih wilayah yang ingin dianalisis, kemudian sistem menampilkan hasil klasifikasi kerawanan tanah longsor dalam bentuk kelas rendah, sedang, atau tinggi. Informasi yang disajikan meliputi lokasi, jenis bencana, kelas kerawanan, skor probabilitas, faktor dominan, peta kerawanan, riwayat kejadian tanah longsor, serta rekomendasi mitigasi yang relevan dengan kondisi lereng dan potensi longsor.



Gambar 3.3 Sketsa Dashboard TERRA-LANDSLIDE

Sketsa dashboard TERRA-FLOOD ditunjukkan pada Gambar 3.4. Tampilan ini memiliki struktur yang serupa dengan modul TERRA-LANDSLIDE, tetapi konten yang disajikan disesuaikan dengan konteks banjir. Hasil klasifikasi kerawanan banjir ditampilkan dalam tiga kelas, yaitu rendah, sedang, dan tinggi. Informasi yang ditampilkan mencakup lokasi, jenis bencana, kelas kerawanan, skor probabilitas, faktor dominan seperti curah hujan, elevasi rendah, jarak ke sungai, dan penggunaan lahan, serta rekomendasi mitigasi yang berkaitan dengan kesiapsiagaan banjir.

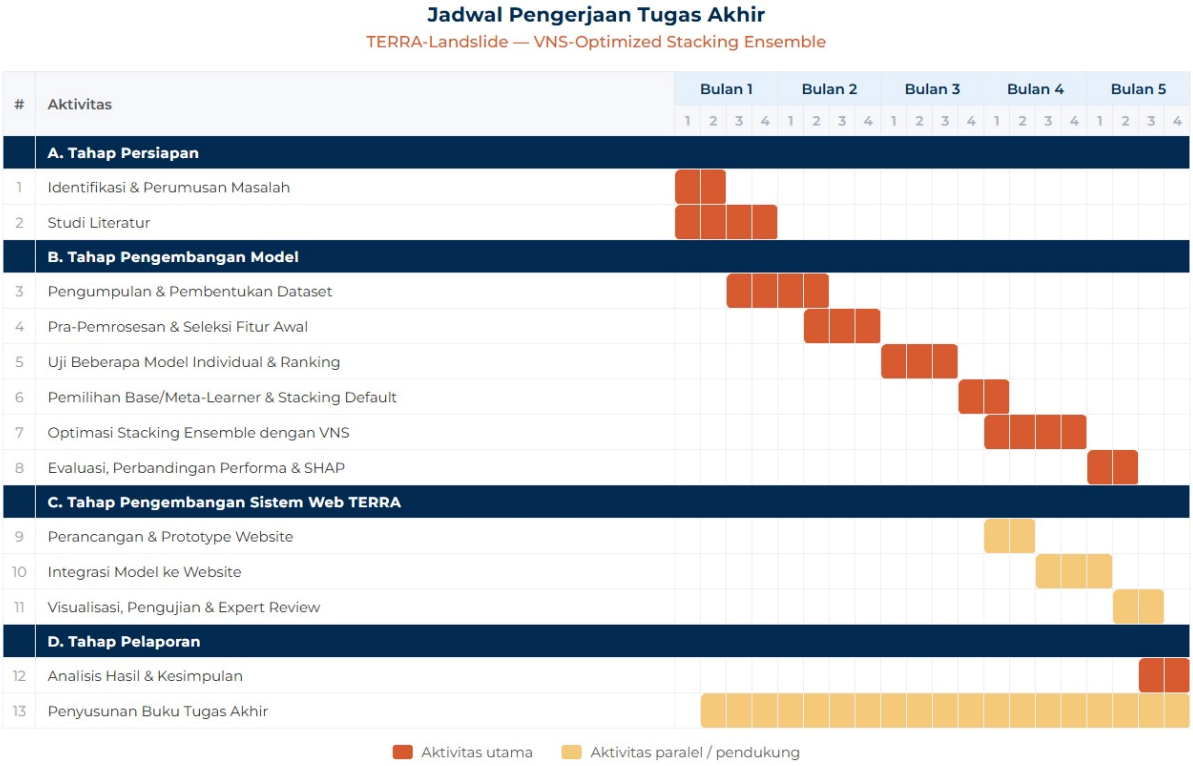


Gambar 3.4 Sketsa Dashboard TERRA-FLOOD

Melalui rancangan dashboard tersebut, sistem TERRA diharapkan dapat menjadi penghubung antara hasil pemodelan berbasis *machine learning* dengan kebutuhan pengguna dalam memahami informasi kerawanan bencana. Dashboard tidak dirancang sebagai sistem peringatan dini operasional secara *real-time*, melainkan sebagai media pendukung penyajian informasi kerawanan dan rekomendasi mitigasi awal berdasarkan hasil klasifikasi model.

3.4 Rencana Pelaksanaan Tugas Akhir

Rencana pelaksanaan tugas akhir disusun untuk menggambarkan pembagian waktu pelaksanaan tugas akhir secara keseluruhan. Rencana ini disusun dalam satuan minggu dan mencakup beberapa tahap utama, yaitu tahap persiapan, pengembangan model, pengembangan sistem web, integrasi model, evaluasi, dan pelaporan. Rencana pelaksanaan tugas akhir ditunjukkan pada Gambar 3.5.



Gambar 3.5 Rencana Pelaksanaan Tugas Akhir

DAFTAR PUSTAKA

Badan Nasional Penanggulangan Bencana. (2025). *Data Bencana Indonesia 2024*. Badan Nasional Penanggulangan Bencana. https://bnpb.go.id/storage/app/media/Buletin%20Info%20Bencana/Buku%20Data%20Bencana%202024/20250613_Buku%20Data%202024.pdf

Badan Nasional Penanggulangan Bencana. (2026). *GIS BNPB*. Diakses pada 12 Mei 2026, dari https://gis.bnpb.go.id/

Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research, 13*, 281–305. https://jmlr.org/papers/v13/bergstra12a.html

Breiman, L. (2001). Random forests. *Machine Learning, 45*, 5–32. https://doi.org/10.1023/A:1010933404324

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery. https://doi.org/10.1145/2939672.2939785

Cruden, D. M., & Varnes, D. J. (1996). Landslide types and processes. In A. K. Turner & R. L. Schuster (Eds.), *Landslides: Investigation and mitigation* (pp. 36–75). National Academy Press.

de Lacy, N., Ramshaw, M. J., & Kutz, J. N. (2022). Integrated evolutionary learning: An artificial intelligence approach to joint learning of features and hyperparameters for optimized, explainable machine learning. *Frontiers in Artificial Intelligence, 5*, 832530. https://doi.org/10.3389/frai.2022.832530

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research, 3*, 1157–1182. https://jmlr.org/papers/v3/guyon03a.html

Guzzetti, F., Reichenbach, P., Ardizzone, F., Cardinali, M., & Galli, M. (2006). Estimating the quality of landslide susceptibility models. *Geomorphology, 81*(1–2), 166–184. https://doi.org/10.1016/j.geomorph.2006.04.007

Hu, X., Zhang, H., Mei, H., Xiao, D., Li, Y., & Li, M. (2020). Landslide susceptibility mapping using the stacking ensemble machine learning method in Lushui, Southwest China. *Applied Sciences, 10*(11), 4016. https://doi.org/10.3390/app10114016

Huan, Y., Song, L., Khan, U., & Zhang, B. (2023). Stacking ensemble of machine learning methods for landslide susceptibility mapping in Zhangjiajie City, Hunan Province, China. *Environmental Earth Sciences*.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer. https://www.statlearning.com

Jiang, W., Chen, Z., Xiang, Y., & Zhang, J. (2019). SSEM: A novel self-adaptive stacking ensemble model for classification. *IEEE Access*, *7*, 120337-120349. https://doi.org/10.1109/ACCESS.2019.2937366

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems, 30*. https://papers.nips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

Le, X.-H., Choi, C., Eu, S., Yeon, M., & Lee, G. (2024). Quantitative evaluation of uncertainty and interpretability in machine learning-based landslide susceptibility mapping through feature selection and explainable AI. *Frontiers in Environmental Science*, *12*, 1424988. https://doi.org/10.3389/fenvs.2024.1424988

Lee, S.-M., & Lee, S.-J. (2024). Landslide susceptibility assessment of South Korea using stacking ensemble machine learning. *Geoenvironmental Disasters, 11*, 7. https://doi.org/10.1186/s40677-024-00271-y

Liu, L.-L., Danish, A., Wang, X.-M., & Zhu, W.-Q. (2024). Ensemble stacking: A powerful tool for landslide susceptibility assessment—A case study in Anhua County, Hunan Province, China. *Geocarto International*, *39*(1), 2326005. https://doi.org/10.1080/10106049.2024.2326005

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems, 30*. https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

Merghadi, A., Yunus, A. P., Dou, J., Whiteley, J., ThaiPham, B., Bui, D. T., Avtar, R., & Abderrahmane, B. (2020). Machine learning methods for landslide susceptibility studies: A comparative overview of algorithm performance. *Earth-Science Reviews, 207*, 103225. https://doi.org/10.1016/j.earscirev.2020.103225

Mitchell, T. M. (1997). *Machine learning*. McGraw-Hill.

Mufarida, B. (2024, Juli 10). *Tanah longsor bencana paling mematikan di Indonesia sepanjang 2024*. SINDOnews.com. https://nasional.sindonews.com/read/1412593/15/tanah-longsor-bencana-paling-mematikan-di-indonesia-sepanjang-2024-1720570037

Mladenović, N., & Hansen, P. (1997). Variable neighborhood search. *Computers & Operations Research, 24*(11), 1097–1100. https://doi.org/10.1016/S0305-0548(97)00031-2

Pambudi, D., & Kawamura, M. (2022). Constructing the neighborhood structure of VNS based on binomial distribution for solving QUBO problems. *Algorithms, 15*(6), 192. https://doi.org/10.3390/a15060192

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems, 31*. https://papers.nips.cc/paper_files/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html

Radomirović, B., Bačanin, N., Antonijević, M., Nikolić, B., Filipović, A., Petrović, A., Stoean, R., Zivkovic, M., & Kandasamy, V. (2024). Optimizing long-short term memory neural networks for electroencephalogram anomaly detection using variable neighborhood search with dynamic strategy change. *Complex & Intelligent Systems, 10*, 7987–8009. https://doi.org/10.1007/s40747-024-01592-z

Reichenbach, P., Rossi, M., Malamud, B. D., Mihir, M., & Guzzetti, F. (2018). A review of statistically-based landslide susceptibility models. *Earth-Science Reviews, 180*, 60–91. https://doi.org/10.1016/j.earscirev.2018.03.001

Sahin, E. K. (2022). Comparative analysis of gradient boosting algorithms for landslide susceptibility mapping. *Geocarto International, 37*(9), 2441–2465.

Shapley, L. S. (1953). A value for n-person games. In H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the theory of games II* (pp. 307–317). Princeton University Press.

Song, Y., Song, Y., Wang, C., Wu, L., Wu, W., Li, Y., Li, S., & Chen, A. (2024). Landslide susceptibility assessment through multi-model stacking and meta-learning in Poyang County, China. *Geomatics, Natural Hazards and Risk*.

Syed, M. N. (2023). Feature selection in machine learning via variable neighborhood search. *Optimization Letters, 17*, 2321–2345.

Tempo Data. (2024). *Banjir dan tanah longsor, bencana alam paling sering terjadi di Indonesia*. Tempo. https://www.tempo.co/data/data/banjir-dan-tanah-longsor-bencana-alam-paling-sering-terjadi-di-indonesia-991225

Vapnik, V. N. (1995). *The nature of statistical learning theory*. Springer.

Wolpert, D. H. (1992). Stacked generalization. *Neural Networks, 5*(2), 241–259. https://doi.org/10.1016/S0893-6080(05)80023-1

Xu, Q., Yordanov, V., Amici, L., & Brovelli, M. A. (2024). Landslide susceptibility mapping using ensemble machine learning methods: A case study in Lombardy, Northern Italy. *International Journal of Digital Earth, 17*(1), 2346263. https://doi.org/10.1080/17538947.2024.2346263